

-自动化学院学科核心课-

检测技术与自动化

第6章 现代检测技术-1-多传感器信息融合





1. 多传感器信息融合

1.1 多传感器信息融合的定义

1.2 多传感器信息融合基本原理

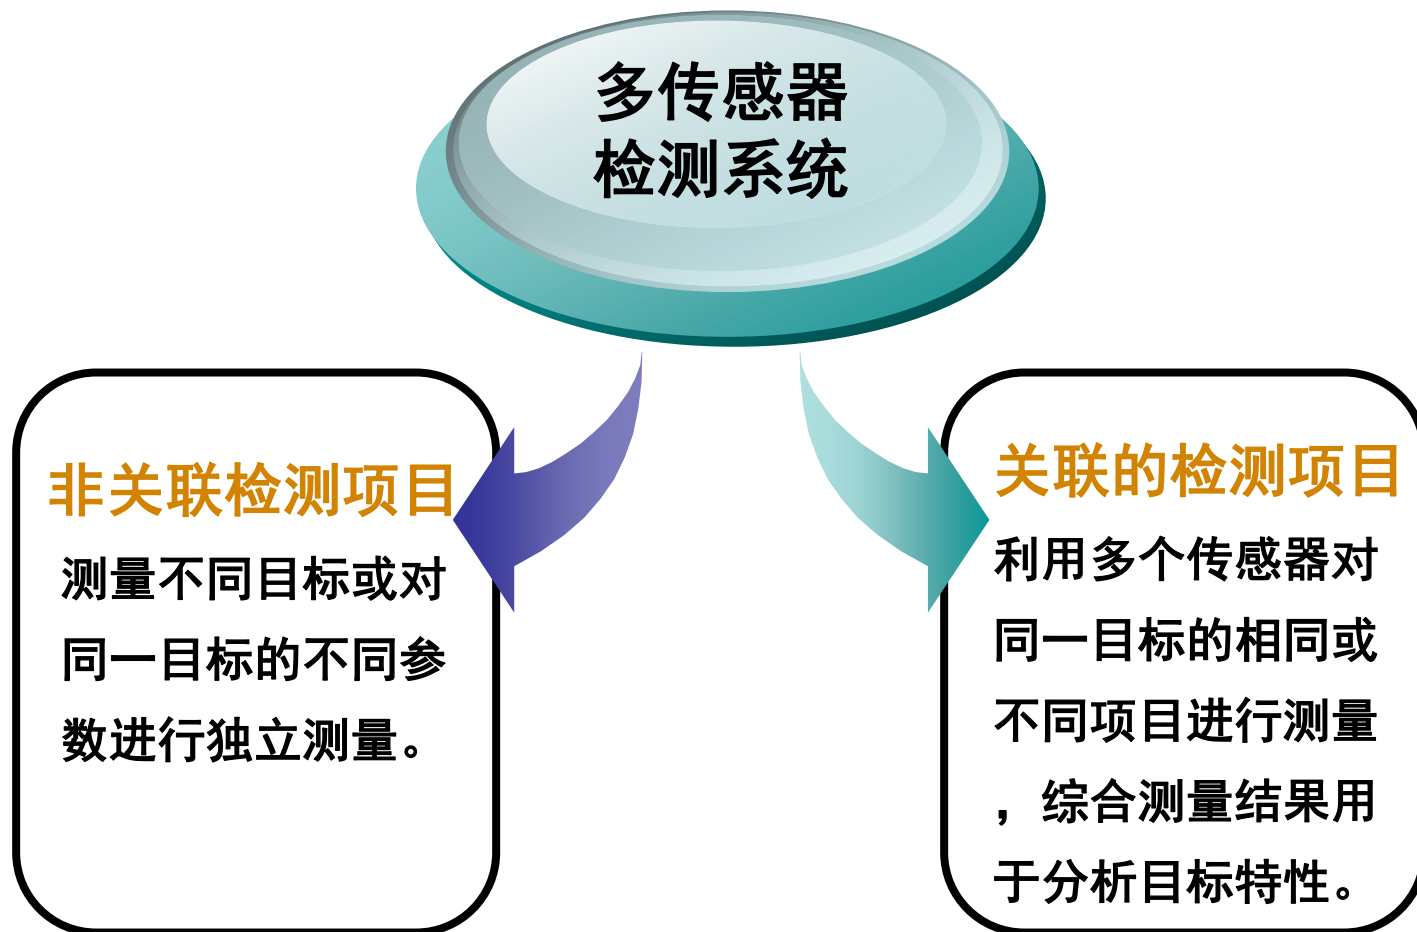
1.3 多传感器信息融合体系结构

1.4 多传感器信息融合的时空性问题

1.5 信息融合常用算法及应用

1.1 多传感器信息融合的定义

多传感器问题的引入



为什么要采用多个传感器测量同一目标参数？





信息融合的定义

- 美国国防部定义（军事应用角度）：

来自许多传感器和信息源的数据进行联合(Association)、相关(Correlation)、组合(Combination)和估值的处理，以达到精确的位置估计(Position Estimation)与身份估计(Identity Estimation)，以及对战场情况和威胁及其重要程度进行完整评估。

- 技术定义：

充分利用不同时间与空间的多传感器数据资源，采用计算机技术按时间序列获得多传感器的观测数据，在一定准则下进行分析、综合、支配和使用。获得对被测对象的一致性解释与描述，进而实现相应的决策和估计，使系统获得比它各组成部分更为充分的信息。

信息融合技术的发展




1.2 多传感器信息融合基本原理


❖ 自然界同类多传感器信息融合

左目和右目的视觉传感器分别获取二维图象信息，经大脑融合后产生立体图象信息；

左耳和右耳的听觉传感器分别获取一维声音信息，经大脑融合后产生立体声音信息。



❖ 自然界异类多传感器信息融合



处理过程特点：

复杂性（信息的来源）、**自适应性**（对外界）
歧义性（信息的解读）、**不完整性**（盲人摸象）
与人的已有知识密切相关



从人处理多源信息到多传感器信息融合：

1) 人信息处理能力的过程

特点：

- ① **自适应性**(信息的多样性)
- ② **高智能化处理**(各种解决手段)
- ③ **先验知识**(先验知识越丰富，综合信息处理能力越强)

2) 传感器感测外部信息，信息融合系统模仿人的信息处理能力

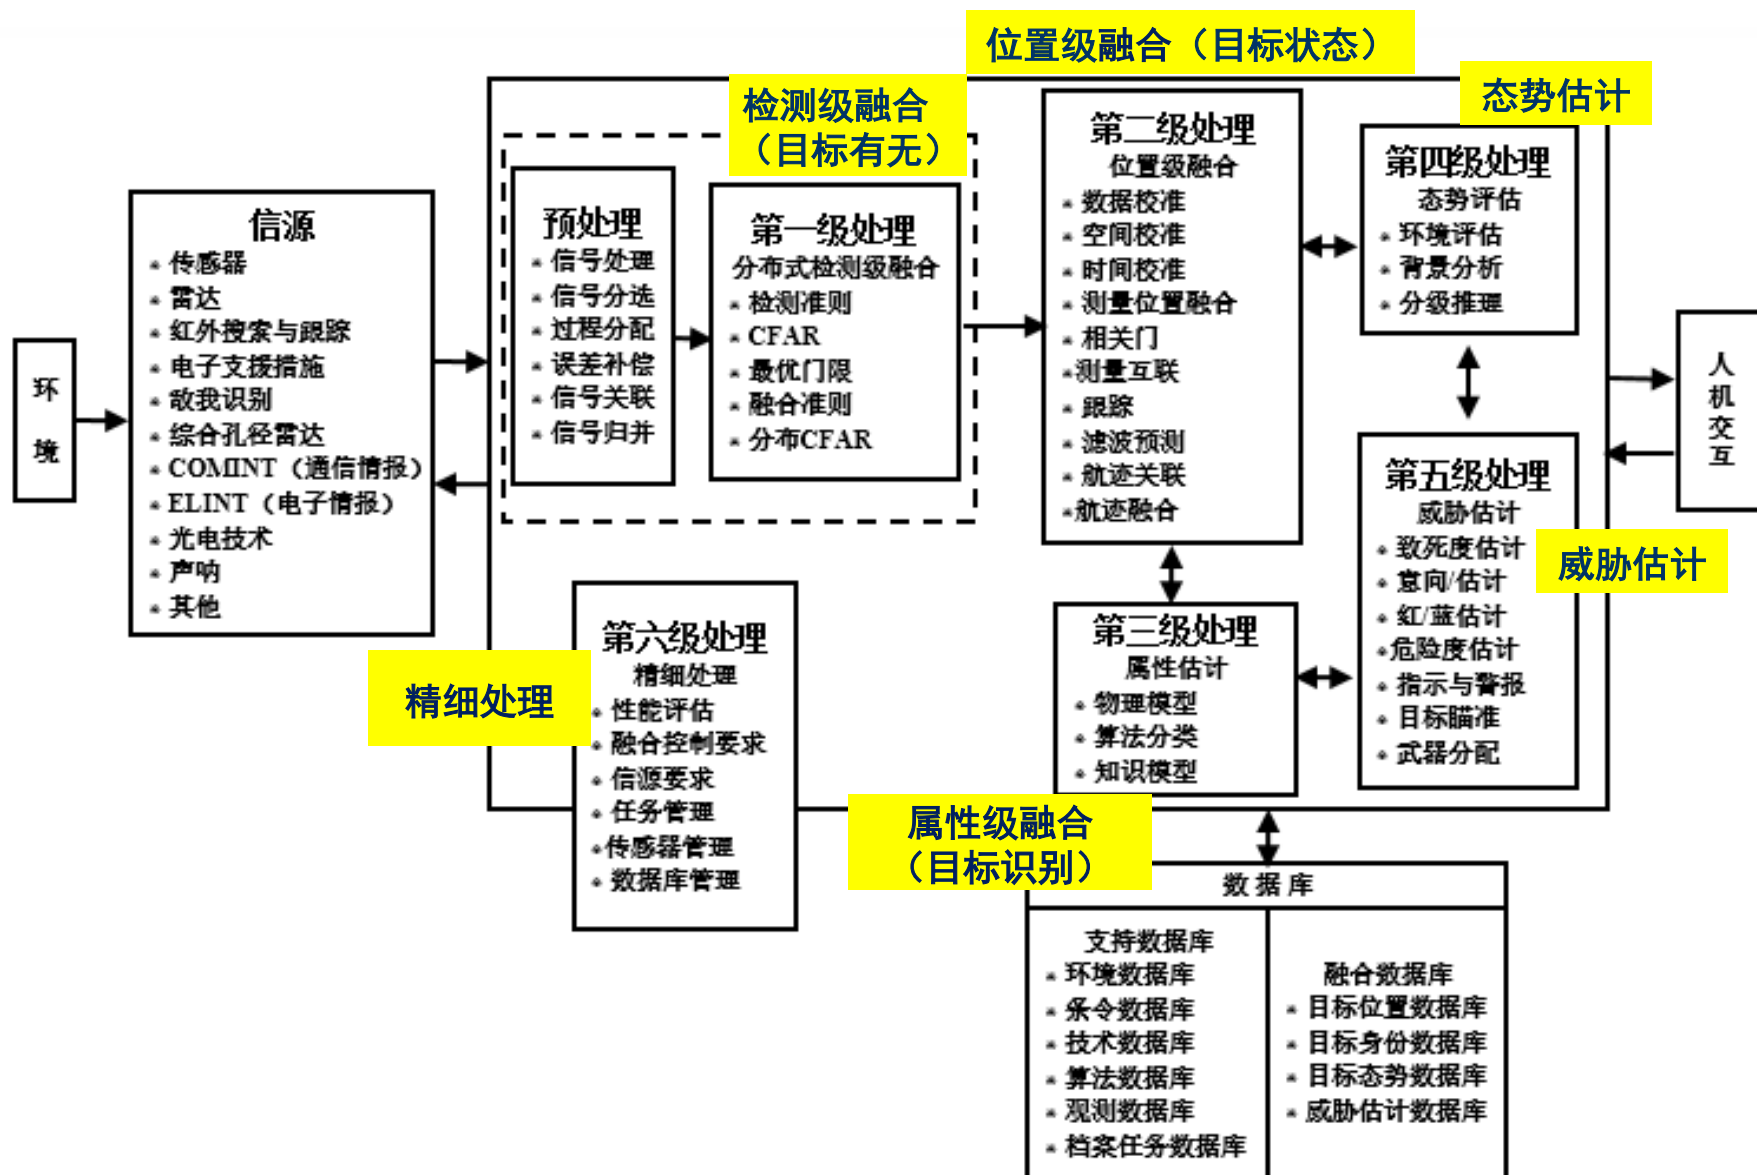
特点：

利用多传感器资源，把多传感器在**空间**或**时间**上可**冗余**或**互补**信息依据某种准则来进行组合，获得被测对象的一致性描述。





1.3 多传感器信息融合体系结构



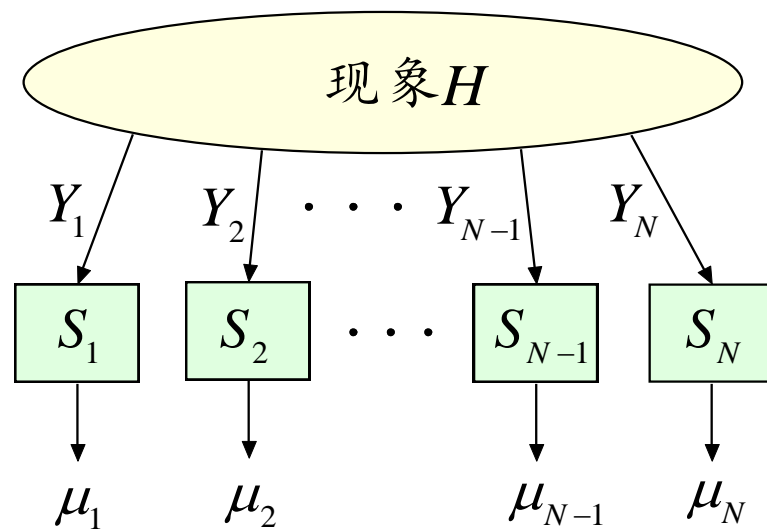
❖ 信息融合系统的结构模型

融合主要发生在检测级、位置级和属性级，主要考虑前三级：

(1) 检测级融合结构


直接在多传感器分布检测系统汇总检测判决或信号层上进行的融合，有多种结构。

a) 分散式结构：每个局部决策都是最终决策，可按某种规则将分离的子系统联合视为一个大系统，并遵循大系统中的某种最优化准则来确定每个子系统的工作点。



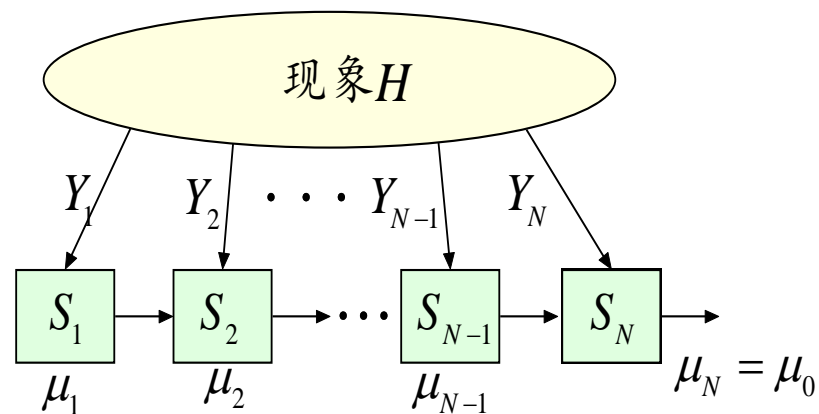
分散式结构

b) 并行结构：每个局部节点的传感器在收到未经处理原始数据后，在局部节点分别作出局部检测判决，然后在检测中心通过融合得到全局决策。普遍应用于分布式检测系统中。



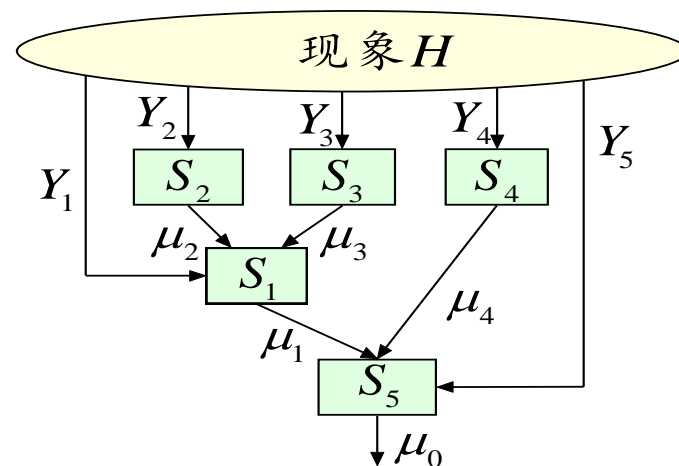
并行结构

c) 串行结构：每个局部节点接收各自检测后，首先由节点1作出局部判决，然后将它通信到节点2，而节点2则将它本身的检测与之融合形成自己的判决，以后，重复前面的过程，并将最后一个节点的判决作为全局判决。



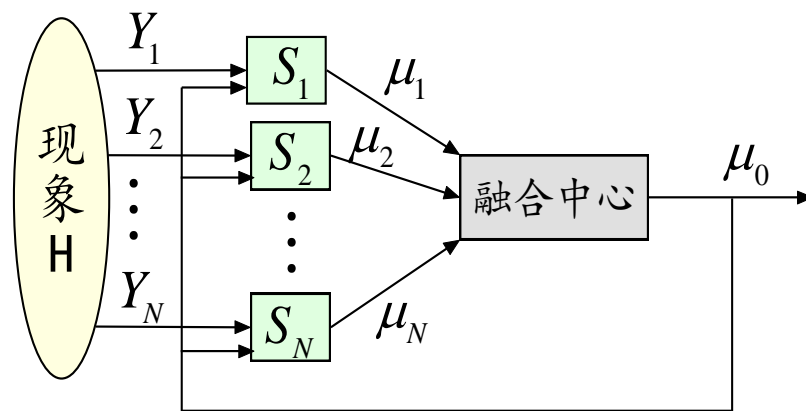
串行结构

d)树状结构：信息传递处理流程是从所有的树枝到树根，最后，在树根(融合节点)融合从树枝传来的局部判决和自己的检测，作出全局判决。



树状结构

e)并行结构：每个局部检测器在接收到观测后，把它们的判决送到融合中心，中心通过某种准则组合这些判决，然后把获得的全局判决分别反馈到各局部传感器作为下一时刻局部决策的输入。这种系统可明显地改善各局部节点的判决质量。

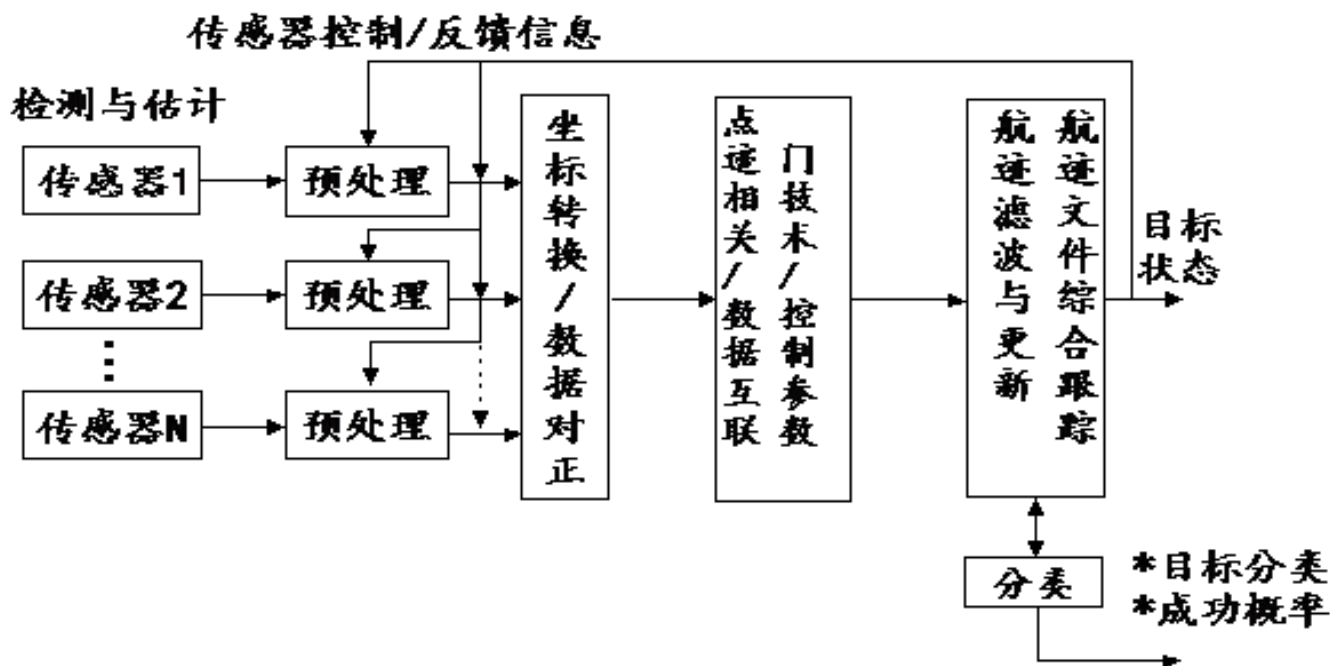


带反馈的并行结构

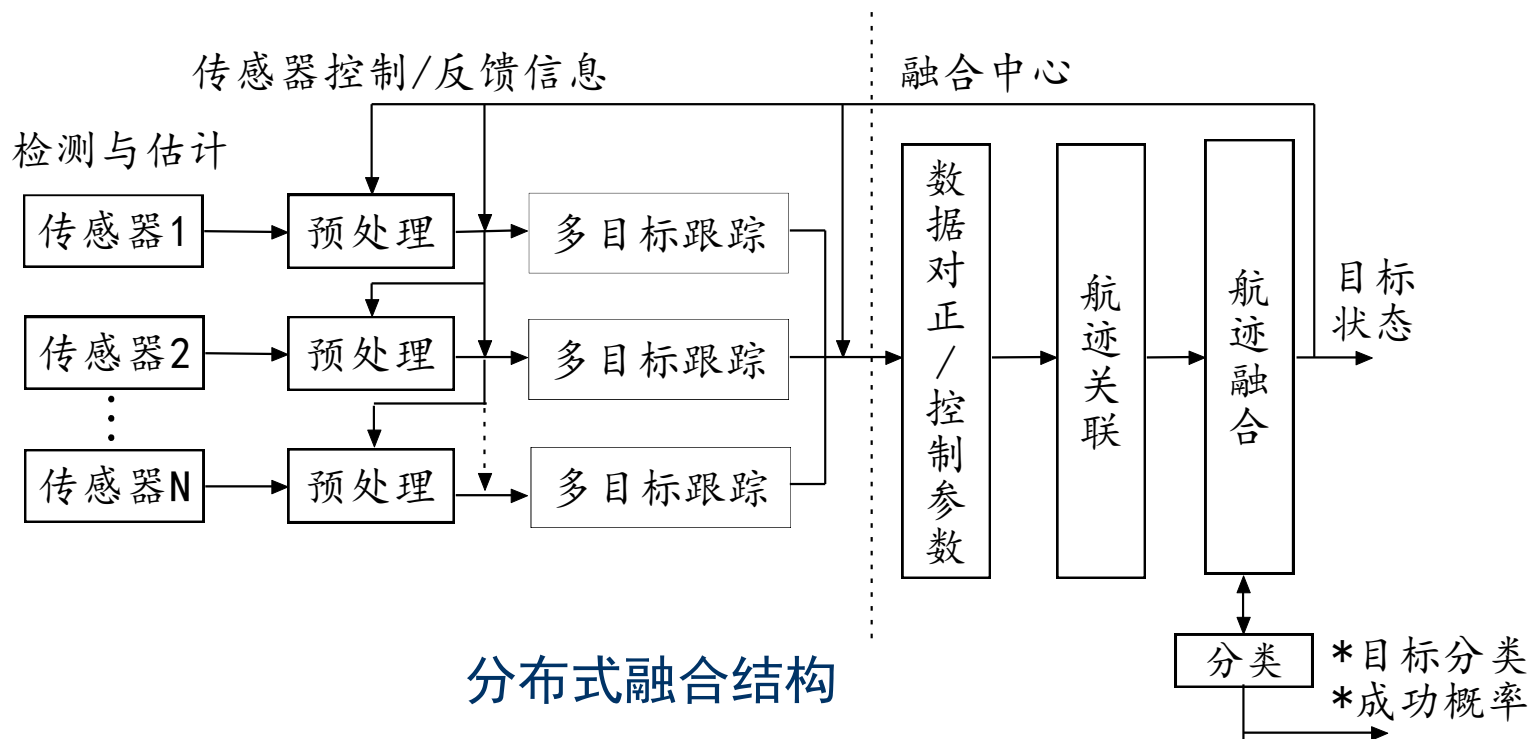
(2) 位置级融合结构（目标状态，时、空融合，最重要）

从多传感器系统信息流通形式和综合处理层次上划分为四种：

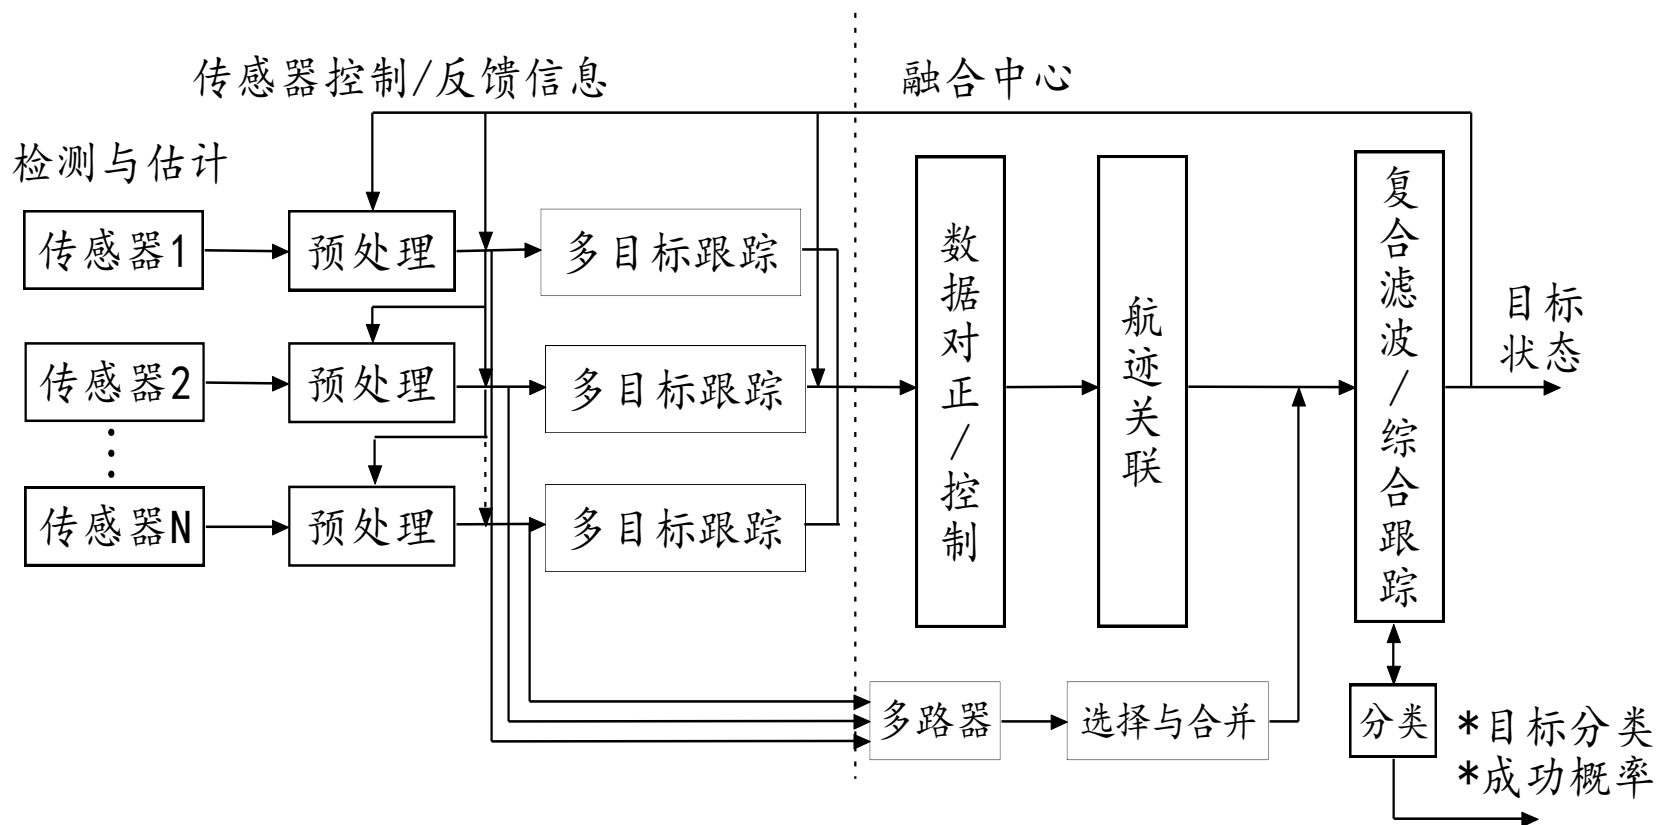
a) 集中式结构：将传感器获取的检测报告传递到融合中心，进行数据对准、点迹相关、数据关联、航迹滤波、预测与综合跟踪。结构最大优点是信息损失最小，但数据关联较困难，并且要求系统必须具备大容量的处理能力，计算负担重，系统的生存能力也相对较差。



b) 分布式结构：每个传感器检测报告融合前，先由自己的数据处理器产生局部多目标跟踪航迹，然后把处理过的信息送至融合中心。中心根据各节点的航迹数据完成航迹关联和航迹融合，形成全局估计，这类系统不仅具有局部独立跟踪能力，而且还有全局监视和评估特征能力。系统的造价也可限制在一定的范围内，并且有较强的自下而上能力。

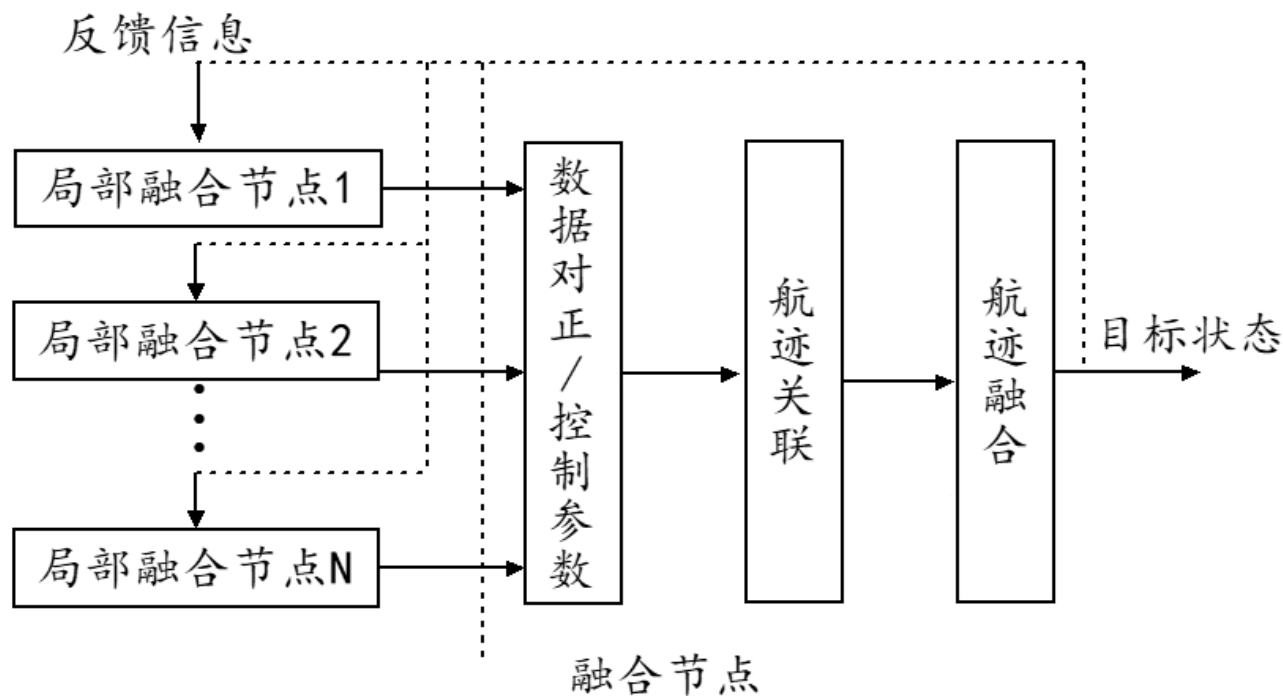


c) 混合式结构：同时传输检测报告和经过局部节点处理过的航迹信息，它保留了上述两类系统的优点，但在通信和计算上要付出代价。



混合式融合结构

d)多级式结构：各局部节点可以同时或分别是集中式、分布式或混合式融合中心，它们将接收和处理来自多个传感器的数据或来自多个跟踪器的航迹，而系统的融合节点要再次对各局部融合节点传送来的航迹数据进行关联和融合，也就是说目标的检测报告要经过两级以上的位置融合处理。

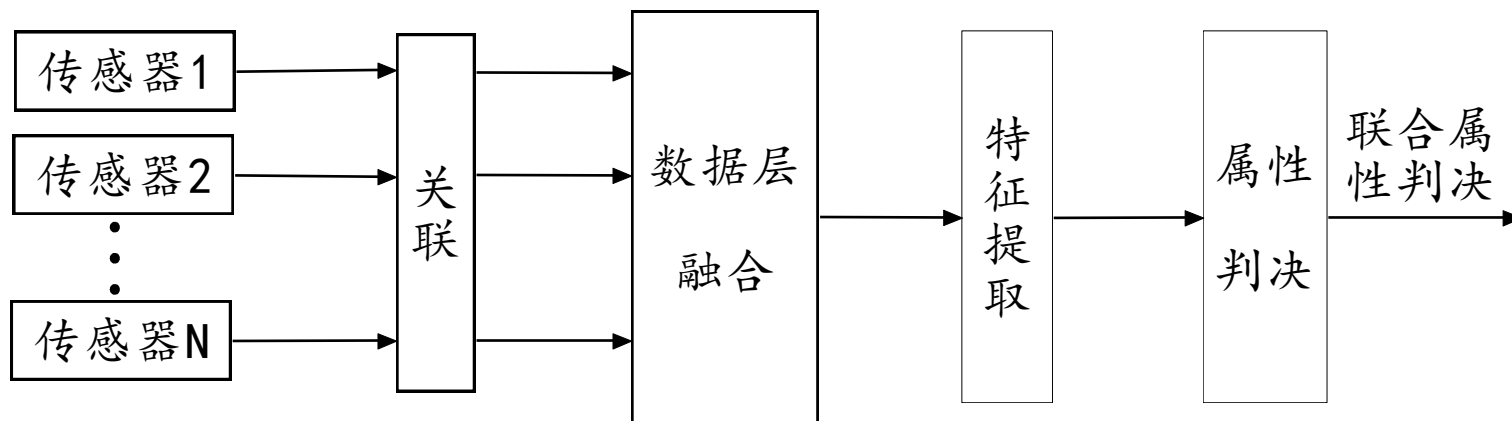


(3) 属性级融合结构（目标识别融合结构）

目标识别(属性)数据融合结构主要分三种：

a) 在数据层属性融合结构：


直接融合来自同类传感器的数据，然后是特征提取和来自融合数据的属性判决。为了完成这种数据层融合，传感器必须是相同的或者是同类的。



数据层属性融合结构

b) 特征层属性融合结构:

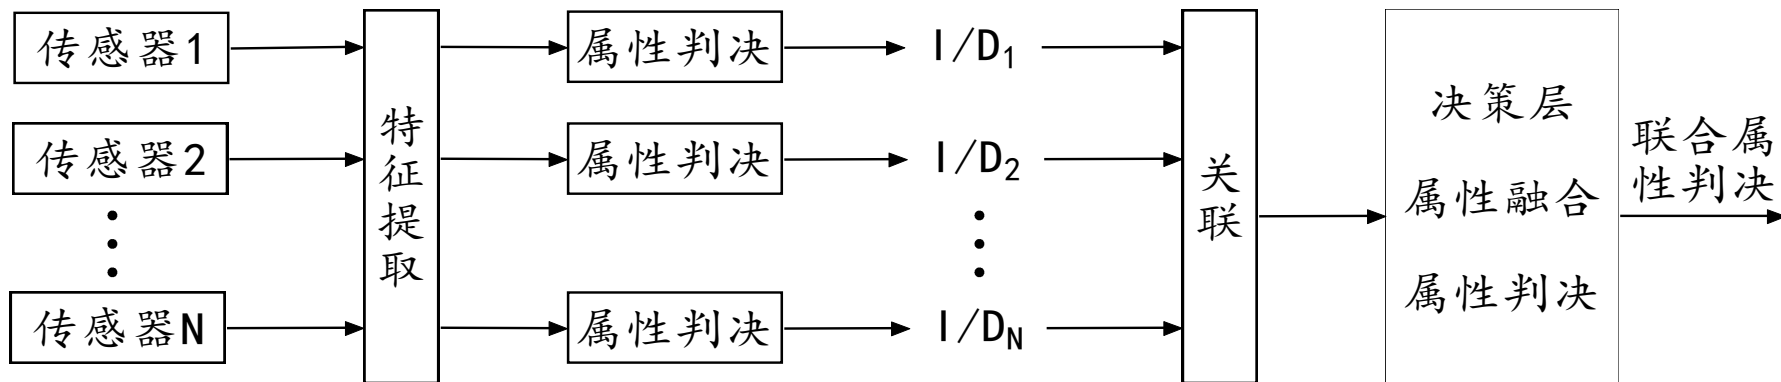
每个传感器观测一个目标，并且为了产生来自每个传感器的特征向量要完成特征提取，然后融合这些特征向量，并基于联合特征向量作出属性判决。另外，为了把特征向量划分成有意义的群组必须运用关联过程。



特征层属性融合结构

c)决策层属性融合结构:

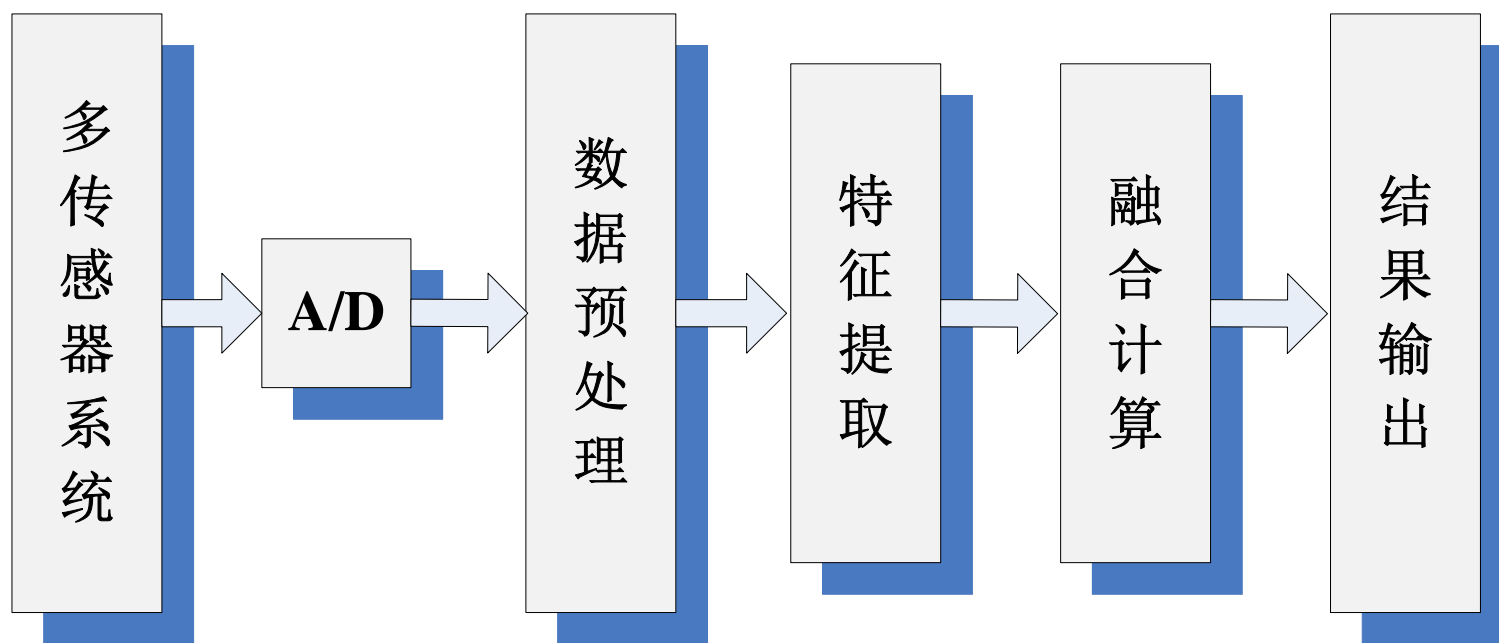
每个传感器为了获得一个独立的属性判决要完成一个变换，然后顺序融合来自每个传感器的属性判决。




决策层属性融合结构



1.4 多传感器信息融合的时空性问题



信息融合的时间性和空间性



不同空间位置上的多传感器在对运动目标进行观测时，各传感器在不同时间和不同空间的观测值有所不同，从而形成一个观测值集合。

【例】 s 个传感器在 n 个时刻观测同一个目标可有 $s*n$ 观测值，其集合 Z 为：

$$Z = \{Z_j\} \quad (j=1,2,\dots,s)$$

$$Z_j = \{Z_j(k)\} \quad (k=1,2,\dots,n)$$

Z_j : j 号传感器观测值集合；

$Z_j(k)$: j 号传感器在 k 时刻观测值。

信息融合的时间和空间配准：

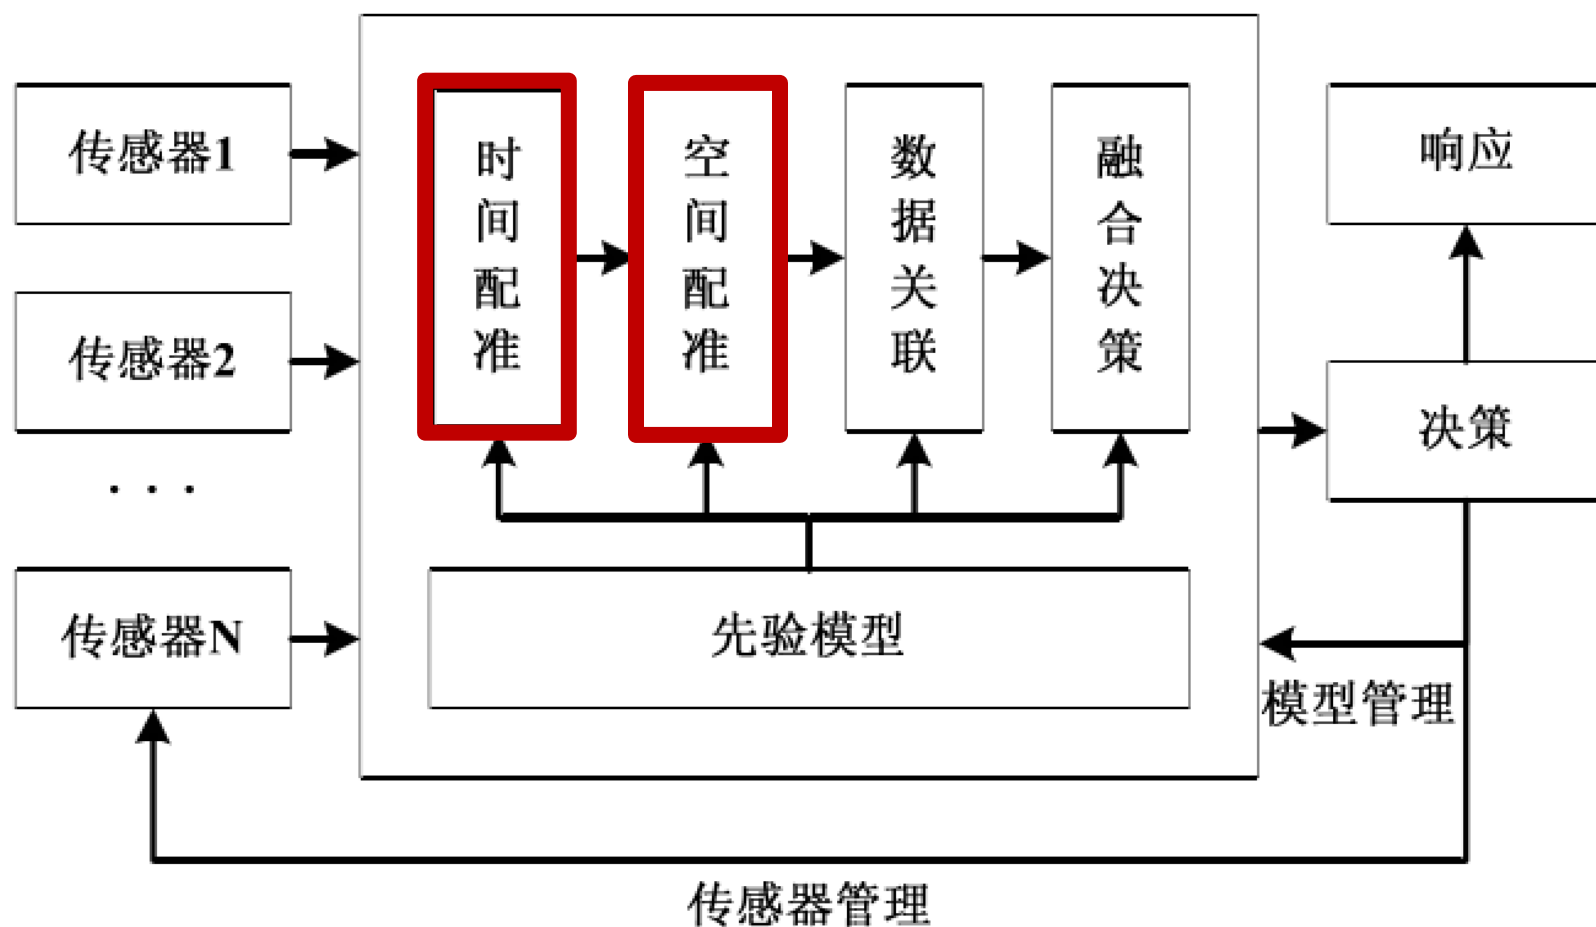
每个传感器获得的信息必须是在同一个空间的同一时刻的描述，需要时空配准。

□ 空间配准：

采用不同坐标系的各传感器的测量，融合时必须将它们转换到同一坐标系中的数据，以保证每个传感器得到的信息是在同一个坐标系下的描述。

□ 时间配准：

将关于同一目标的各传感器不同步的测量信息同步到同一时刻。




□ 空间配准：

信息融合之前，须对坐标系进行统一，统一为信息处理中心的公共坐标系。

例如，信息处理中心常采用直角坐标系，三坐标雷达为 x, y, z 坐标。但雷达和多数传感器所给出的坐标数据是以极坐标的形式给出的，即给出的是目标的斜距 R 、方位角 α 和仰角 β ，在进行数据处理时，需要进行坐标系转换。直角坐标系的三个分量为：

$$\begin{cases} x = R \cos \beta \cos \alpha \\ y = R \cos \beta \sin \alpha \\ z = R \sin \beta \end{cases}$$





□ 时间配准：

多传感器工作时，在时间上是不同步的，主要由以下几方面原因造成：

- 各传感器开机的时间是不一样的
- 各传感器的采样率可能不同
- 观测数据不是在同一时刻得到，存在观测数据的时间差
- 传输延迟等

这样，在融合之前必须将这些观测数据同步，或者称作时间对准，即统一“时基”。

通常，利用一个传感器的时间作为公共处理时间，把来自其它传感器的时间都统一到该传感器的时间上。



□ 时间配准:

- 通过硬件手段使得各传感器数据在开始的时间上对齐
- 内推外插法: 对各传感器所采集的采样频率不同的目标观测数据进行内插、外推, 将大粒度的观测时间点上的数据推算融合到小粒度的观测时间点上

【例】 想把第 k 个传感器在时间 t_j 的观测状态同步到某个公共处理时间 t_i 上, 有:

$$Z_k(t_i) = Z_k(t_j) + v * (t_i - t_j)$$

v — 目标运动速度

$Z_k(t_j)$ — 在时间 t_j 来自传感器 k 的观测状态数据


$v * (t_i - t_j)$ — 修正项

该式的意义是将第 k 个传感器在时间 t_j 的状态数据同步到公共处理时间 t_i 上。

□ 时间配准:

- 最小二乘虚拟法

当两传感器的采样周期之比为整数时，可以利用最小二乘虚拟法。



假设有传感器A和传感器B，采样周期分别为 T_a 和 T_b ，假设 $T_b > T_a$ ，且两者之比为整数 N 。

目标状态最近一次更新时刻为 $(k-1)T_b$ ，下次更新时刻为 $[(k-1)T_b + NT_a]$ ，则在传感器B对目标状态的一次更新时间内传感器A有 N 次测量值。因此可以采用最小二乘规则法将传感器A的 N 次测量值融合为一个与传感器B采样时刻同步的虚拟测量值，然后再与传感器B的测量值进行融合处理。



$Z_N = [z_1, z_2, \dots, z_N]^T$ 表示传感器A在 $(k-1)Tb \sim kTb$ 时刻的N个测量值集合
 z_N 与传感器B的测量值同步

若用 $U = [z, z']^T$ 表示 z_1, z_2, \dots, z_N 融合以后的测量值及其导数。
则传感器A的测量值 z_i 可以表示成如下形式：

$$z_i = z + (i - N)T_a \cdot z' + v_i \quad i = 1, 2, \dots, N$$

其中 v_i 表示测量噪声，将上式改写为向量形式为：

$$Z_N = W_N U + V_N$$

其中 $V_N = [v_1, v_2, \dots, v_N]^T$ ，其均值为零，方程为

$$E[V_N \cdot V_N^T] = \text{diag}(\sigma^2 \dots \sigma^2)$$

σ^2 为测量噪声方差。



$$W_N = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ (1-N)T_a & (2-N)T_a & \cdots & (N-N)T_a \end{bmatrix}^T$$

根据最小二乘准则有：

$$J = V_N^T V_N = [Z_N - W_N U]^T [Z_N - W_N U]$$

要使得 J 为最小， J 两边对 U 求偏导数并令其等于零得：

$$\frac{\partial J}{\partial U} = -2(W_N^T Z_N - W_N^T W_N U) = 0$$

所以有：

$$U = [z, z']^T = [W_N^T W_N]^{-1} W_N^T Z_N$$

其方差阵估计值为：

$$R_U = \sigma^2 [W_N^T W_N]^{-1}$$



融合后得 kT_b 时刻的测量值及测量噪声方差为：

$$z(k) = c_1 \sum_{i=1}^N z_i + c_2 \sum_{i=1}^N i \cdot z_i$$

$$\text{Var}[z(k)] = \frac{2\sigma^2(2N+1)}{N(N+1)}$$

其中，

$$c_1 = -2/N, c_2 = 6/N$$

当传感器采样周期之比不为整数时，一般不能应用最小二乘虚拟法，但当融合周期为所有传感器采样周期的整数倍时也可以采用。设有两传感器A和B，其采样周期之比不为整数，设为 M/N ，此时可以采用最小二乘规则将传感器A的 N 次测量值和传感器B的 M 次测量值分别虚拟为采样时刻同步时的传感器A和B的测量值，然后进行融合处理。



□ 时间配准：

- 曲线拟合法

基本思想：无论高数据率的空中目标，还是低数据率的水面目标或水下目标，或静止目标，从时间来看，所得到的目标测量数据均可视为目标的一条运动曲线。

保持拟合误差最小原则，对目标进行曲线拟合，得到拟合曲线，然后根据选择好的采样间隔进行采样，得到该目标再采样间隔下的目标点迹，实现目标的时间配准。

若已知数据集 $(x_i, y_i)(i = 0, 1, \dots, n)$ ，拟合的曲线为 $P(x)$ ，误差 δ_i 可表示为

$$\delta_i = P(x_i) - y_i (i = 0, 1, \dots, n)$$

按照某种标准，使得 δ_i 达到最小，一般是按离散误差平方和最小（即最小二乘）

$$\sum_{i=0}^n \delta_i^2 = \min$$



在此条件下的曲线拟合方法称为数据拟合的最小二乘法。基于最小二乘法的数据拟合是一种平均意义下的衡量规则。通常采用多项式形式的 $P(x)$ ，即在函数类 $\varphi = \{\varphi_0, \varphi_1, \dots, \varphi_m\}$ 中找到一个函数组合 $P(x)$ 。

$$P(x) = \sum_{j=0}^m (a_j \varphi_j(x))$$

使误差平方和最小，即：

$$\|\delta\|^2 = \sum_{i=1}^n \delta^2 = \sum_{i=1}^n (P(x_i) - y_i)^2$$

用最小二乘求拟合问题就是求 $P(x)$ 使 $\|\delta\|^2$ 取得最小值。求拟合曲线函数的过程就转化为求多元函数极小值的问题，多元函数如下：

$$I(a_0, a_1, \dots, a_m) = \sum_{i=1}^n \delta^2$$

用最小二乘求拟合问题就是求 $P(x)$ 的最小二乘解为：

$$P(x) = \sum_{j=0}^m (a_j \varphi_j(x))$$


基于数据拟合的时间配准方法，其核心是将数据融合中的一个或多个传感器的测量数据，基于最小二乘准则经过数据拟合，得到一条或几条平滑曲线，由拟合后的曲线可以得到传感器在任意时刻的量测值，根据其他传感器的采样周期，从曲线解析式得到相应时刻的测量值，从而可以方便地和其他传感器进行时间配准，继而进行信息数据融合。

□ 时间配准:

- 串行合并法

将不同传感器对同一目标在不同时刻的测量数据直接组合成一个传感器的测量数据，然后进行融合处理。

处理非同步采样数据一般是采取时间校正的办法，将异步数据转换为同步数据，然后再进行融合。但在目标机动的情况下进行时间校正不一定是必要的，也可以通过异步数据的特点来增强传感器系统的数据采样率，即采用串行合并法。





对合并后的数据可以采取先融合后跟踪的处理方法。如融合中心收到了传感器A的观测状态矢量 $[x_a(t_k), y_a(t_k)]$ 和相邻时刻的传感器B的状态观测矢量 $[x_b(t_{k+1}), y_a(t_{k+1})]$ ，直接对这两个状态矢量进行加权平均融合。

串行合并法通常只能得到非周期的同步数据，而且传感器测量数据的系统误差会对配准精度产生较大影响。要求处理前各传感器的数据类型和时空坐标要统一，仅适用于融合系统对融合时刻没有要求的情况。



时间配准还有拉格朗日插值法、样条函数插值法等。

此外，还要注意量纲对准，即把各传感器送来的参数量纲进行统一，以便于后续计算。

时空性是目标运动状态观测的主要问题：

信息融合的时间性

- 按时间先后对观测目标在不同时间的观测值进行融合
- 利用单传感器不同时间的观测结果进行信息融合时，要考虑信息融合的时间性

信息融合的空间性

- 对同一时刻不同空间位置的多传感器进行信息融合
- 利用多传感器在同一时刻的观测结果进行信息融合时，要考虑信息融合的空间性。



时空性的处理方法：

为获得观测目标的准确状态，同时考虑信息融合的时间性与空间性。

实现方法：

①先对各传感器**不同时间**的观测值集进行融合，得出每个传感器对目标状态的估计，然后将各个传感器的估计进行空间融合，从而得到目标状态的最终估计。

②在**同一时间**对**不同空间位置**的各传感器的观测值进行融合，得出各不同时间的观测目标估计，然后对不同时间的观测目标估计按时间顺序进行融合，得出最终状态。

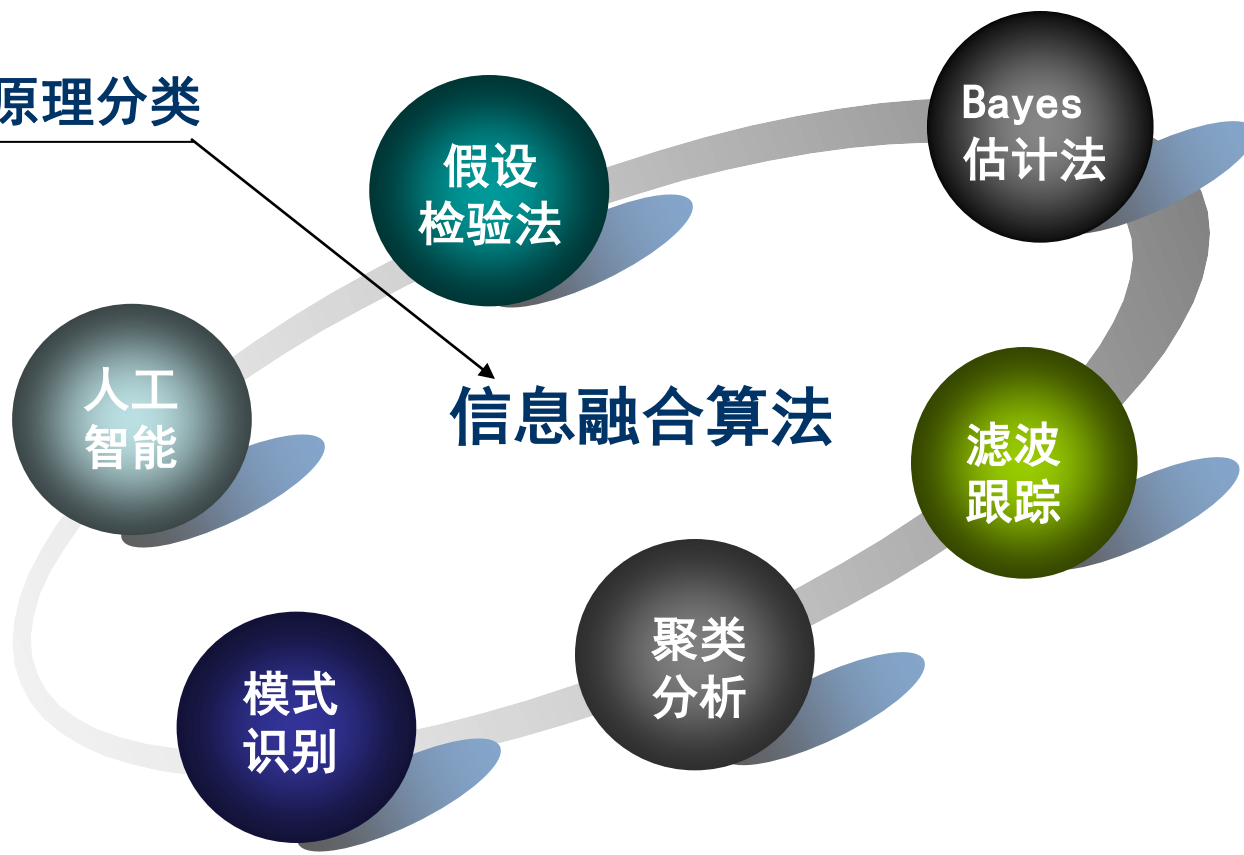


③**同时考虑信息融合的时间性与空间性**，即上述两个同时进行，可以减少信息损失，提高信息融合系统的实时性。但同时进行的难度大，只适合于大型多计算机的信息融合系统。



1.5 信息融合常用算法及应用

按技术原理分类





传感器信息的不确定性

传感器输出不可能
包含被测量全部、完整的信息

噪声破坏

可靠度

精度


目标因素



- 加权平均法：
最简单直观，将多个传感器提供的冗余信息进行加权平均。调整设置权值工作量大，主观性强。
- Bayes估计理论：
 - Bayes方法具有严格的理论基础，应用广泛；
 - 采用归纳推理的方法对多源信息进行有效地融合；
 - 充分利用了测量对象的先验信息。
- D-S证据推理的信息融合：
 - D-S推理是Bayes推理的扩充；
 - 精度和信度是预定的，不依赖于样本。



- 滤波跟踪型数据融合算法：
 - 利用数字滤波方法根据测量值估计被测量真值；
 - 利用当前和历史测量数据估计目标未来状态。
- 神经网络方法：
 - 是一种规则透明的非线性映射方法；
 - 信息存储于网络结构和连接权值；
 - 增强了信息处理的容错性；
 - 具有自组织和自学习能力。



-自动化学院学科核心课-

检测技术与自动化

第6章 现代检测技术-2-多传感器信息融合





2 基于Bayes估计的信息融合方法及应用

2.1 Bayes统计理论

2.2 基于Bayes估计的身份识别方法

2.3 基于Bayes估计的传感器检测数据融合

2.1 Bayes统计理论

在考虑可靠度情况下传感器测量需要解决的一个关键问题：真值和测量值。

考察一个随机试验，在该试验中 n 个互不相容的事件 A_1, A_2, \dots, A_n 必然会发生一个，且只能发生一个，用 $P(A_i)$ 表示 A_i 发生的概率，则有：

$$\sum_{i=1}^n P(A_i) = 1$$

❖ 设利用一传感器对 A 事件的发生进行检测，检测结果为 B ，则 A_i 为真值， B 为测量值。



- ❖ Bayes统计理论认为，人们在检验前后对某事件的发生情况的估计是不同，而且一次检验结果不同对人们的最终估计的影响是不同的。
- ❖ 先验知识：
 $P(A_1)$ 、 $P(A_2)$ 、...、 $P(A_n)$ 表示事件 A_1, A_2, \dots, A_n 发生的概率，这是试验前的知识称为“先验知识”。
- ❖ 后验知识：
由于一次检验结果 B 的出现，改变了人们对事件 A_1, A_2, \dots, A_n 发生情况的认识，这是试验后的知识称为“后验知识”。



❖ 后验知识:

检验后事件 A_1, A_2, \dots, A_n 发生的概率表现为条件概率:

$$P(A_1|B), P(A_2|B), \dots, P(A_n|B)$$

显然有:

$$P(A_i|B) \geq 0 \quad \sum_{i=1}^n P(A_i|B) = 1$$

Bayes估计:

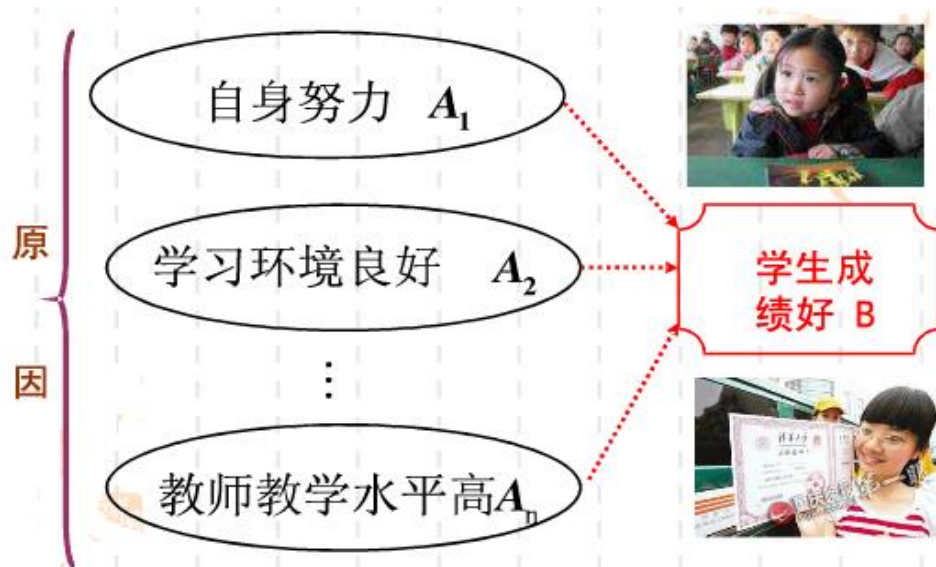
检验过程中对先验知识向后验知识不断修正。

❖ 全概率公式:

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

其中 A_i 为对样本空间的一个划分, 即 A_i 为互斥事件

且 $\sum_{i=1}^n P(A_i) = 1$




$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i).$$



全概率公式和Bayes公式主要用于计算比较复杂事件的概率，它们实质上是加法公式和乘法公式的综合运用。

综合运用



加法公式

$$P(A+B)=P(A)+P(B)$$

A, B 互斥


乘法公式

$$P(AB)=P(A)P(B|A)$$

$$P(A)>0$$


【例1】 有三个箱子，分别编号为1,2,3，1号箱装有1个红球4个白球，2号箱装有2红3白球，3号箱装有3红球。某人从三箱中任取一箱，从中任意摸出一球，求取得红球的概率。

解：记 $A_i = \{\text{球取自} i \text{号箱}\}$,
 $i = 1, 2, 3$;
 $B = \{\text{取得红球}\}$




B 发生总是伴随着 A_1 , A_2 , A_3 之一同时发生，

即 $B = A_1B + A_2B + A_3B$
且 A_1B, A_2B, A_3B 两两互斥



$$\begin{aligned} P(B) &= P(A_1B) + P(A_2B) + P(A_3B) \\ &= \sum P(A_iB) \end{aligned}$$

对求和中的每一项
运用乘法公式得



$$P(B) = P(A_1B) + P(A_2B) + P(A_3B) \\ = \sum P(A_iB)$$

乘法公式


$$P(AB) = P(A)P(B|A) \\ P(A) > 0$$



$$P(B) = \sum_{i=1}^3 P(A_i)P(B|A_i)$$

代入数据计算得： $P(B) = 8/15$

将此例中所用得方法推广到一般情形，
得到在概率计算中常用得全概率公式。



在一些教科书中，常把全概率公式叙述为：

全概率公式：


设 S 为随机试验的样本空间， A_1, A_2, \dots, A_n 是两两互斥的事件，且有 $P(A_i) > 0, i=1, 2, \dots, n$

$\bigcup_{i=1}^n A_i = S$ 则对任一事件 B ，有

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

称满足上述条件的 A_1, A_2, \dots, A_n 为完备事件组。

原因→结果



$$P(B) = \sum_{i=1}^3 P(A_i)P(B|A_i)$$

全概率公式的来由，不难由上式看出：

“全”部概率 $P(B)$ 分解成了许多部分之和，其理论和实用意义在于：

在较复杂情况下直接计算 $P(B)$ 不易，但 B 总是伴随着某个 A_i 出现，适当地去构造这一组 A_i 往往可以简化计算。



还可以从另一个角度去理解 全概率公式

某一事件 B 的发生有各种可能的原因($i=1,2,\dots,n$),
如果 B 是由原因 A_i 所引起, 则 B 发生的概率为:


$$P(BA_i) = P(A_i)P(B|A_i)$$

每一个原因都可能导致 B 发生, 故 B 发生,
则 B 发生的概率是个原因引起 B 发生概率
的总和, 即全概率公式。



2.1 Bayes统计理论

由此可以形象地把全概率公式看成为“**由原因推结果**”，每个原因对结果发生有一定的“作用”，即结果发生的可能性与各种原因的“作用”大小有关，全概率公式表达了它们之间的关系。



诸 A_i 是原因
 B 是结果



【例2】某地成年人体重肥胖者(A_1)占0.1，中等者(A_2)占0.82，瘦小者(A_3)占0.08，又肥胖者、中等者、瘦小者患高血压病的概率分别为0.2，0.1，0.05，求该地成年人患高血压的概率。

解：令 $B = \{ \text{某人患高血压} \}$ （显然 B 是一复杂事件），


$A_i = \{ \text{某人体重的特征} \}$ ($i=1, 2, 3$)

显然它们构成一完备事件组，且事件 B 只能与其中之一事同时发生。故用全概率公式计算。

$$\begin{aligned} P(B) &= P(A_1)P(B|A_1) + P(A_2)P(B|A_2) \\ &\quad + P(A_3)P(B|A_3) \\ &= 0.1 \times 0.2 + 0.82 \times 0.1 + 0.08 \times 0.05 = 0.106 \end{aligned}$$

实际中还有下面一类问题，是“**已知结果求原因**”

某人从任一箱中任意摸出一球，发现是红球，求该球是取自1号箱的概率。



或者问：

该球取自哪号箱的可能性最大？

此类问题更为常见，所求的是条件概率，是已知某结果发生条件下，求各原因发生可能性大小。



贝叶斯 (Bayes) 公式:

设 A_1, A_2, \dots, A_n 是两两互斥的事件, 且 $P(A_i) > 0$, $i=1, 2, \dots, n$, 另有一事件 B , 它总是与 A_1, A_2, \dots, A_n 之一同时发生, 则

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$



证明 由条件概率公式、乘法公式及全概率公式知：

$$P(A_i|B) = \frac{P(BA_i)}{P(B)}$$

结果→原因

$$= \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^n P(B|A_j)P(A_j)}, \quad i = 1, 2, \dots, n.$$

该公式于1763年由贝叶斯(Bayes)给出，它是在观察到事件 B 已发生的条件下，寻找导致 B 发生的每个原因的概率。



贝叶斯公式：结果→原因

先验概率

条件概率


后验概率

$$P(A_i|B) = P(A_i)P(B|A_i) / \sum_{j=1}^n P(A_j)P(B|A_j)$$

将 A_i 看成是导致随机事件 B 发生的各种可能原因，则 $P(A_i)$ 可以理解为随机事件 A_i 发生的**先验概率**(a priori probability)。

若已知随机事件 B 发生这个新信息，则它可以用于对事件 A_i 发生的概率进行重新估计。事件 $P(A_i/B)$ 就是知道了新信息“ B 发生”后对于概率的重新认识，称为随机事件 A_i 的**后验概率**(a posteriori probability)。

【例3】某人从任一罐中任意摸出一球，发现是红球，求该球是取自1号罐的概率。



解：令 $A_i = \{\text{取到第} i \text{号罐}\}, i=1,2,3$
 $B = \{\text{取得红球}\}$

A_1, A_2, A_3 是完备事件组，由贝叶斯公式得：

$$P(A_1|B) = P(B|A_1)P(A_1) / \sum_{i=1}^3 P(A_i)P(B|A_i)$$

其中： $P(B|A_1) = 2/3, P(B|A_2) = 3/4, P(B|A_3) = 1/2$
 $P(A_i) = 1/3, i=1,2,3$

代入数据计算得： $P(A_1|B) \approx 0.348$



【例4】 一个有5个选择的考题，其中只有一个选择正确的，假定应考人知道正确答案的概率为 p 。如果他最后选对了，问他确实知道答案的概率是多少？

解：令 $A=\{ \text{知道答案} \}$

$B=\{ \text{选择正确} \}$

由全概率公式：

$$P(B) = P(B|A)P(A) + P(B|\bar{A})P(\bar{A})$$

$$P(B|\bar{A}) = \frac{1}{5}, \quad P(B|A) = 1, \quad P(A) = p$$



$$\begin{aligned} P(B) &= P(B|A)P(A) + P(B|\bar{A})P(\bar{A}) \\ &= p + \frac{1}{5}(1-p) = \frac{4p+1}{5} \end{aligned}$$

得到: $P(A|B) = P(A)P(B|A) / P(B)$
 $= 5p / (4p + 1)$

例如, 若 $p = \frac{1}{2}$ 则 $P(A|B) = 5 / 6$

说明依据试卷成绩来衡量学生平时的学习状况还是有科学依据的。





【例5】“狼来了”讲的是一个小孩每天到山上放羊，山里有狼出没。第一天，他在山上喊“狼来了！狼来了！”，山下的村民闻声便去打狼，发现狼没有来；第二天仍是如此；第三天，狼真的来了，可无论小孩怎么喊叫，也没有人来救他，因为前两次他说了谎，人们不再相信他了。

现在用贝叶斯公式来分析此寓言中村民对这个小孩的可信程度是如何下降的。

果

因

首先记事件 $B=\{\text{小孩说谎}\}$ ，事件 $A=\{\text{小孩可信}\}$ 。
假设村民过去对这个小孩的印象为：

$$P(A) = 0.8, P(\bar{A}) = 0.2$$



现用贝叶斯公式来求 $P(A|B)$ ，以及这个小孩说了一次谎后，村民对他的可信程度的改变。

在贝叶斯公式中我们要用到 $P(B|A)$ 和 $P(B|\bar{A})$ ，这两个概率的含义是：前者为“可信” (A) 的孩子“说谎” (B) 的可能性，后者为“不可信”孩子“说谎”的可能性，设

$$P(B|A) = 0.1, P(B|\bar{A}) = 0.5$$

第一次村民上山打狼，发现狼没有来，即小孩说了谎 (B)。村民根据这个信息，对小孩的可信程度改变为（用贝叶斯公式）

$$P(A|B) = \frac{P(A)P(B|A)}{P(A)P(B|A) + P(\bar{A})P(B|\bar{A})}$$



$$\begin{aligned} P(A|B) &= \frac{P(A)P(B|A)}{P(A)P(B|A) + P(\bar{A})P(B|\bar{A})} \\ &= \frac{0.8 \times 0.1}{0.8 \times 0.1 + 0.2 \times 0.5} = 0.444 \end{aligned}$$

表明村民上了一次当后，对这个小孩的可信程度由原0.8调整为0.444，也就是

$$P(A) = 0.444, P(\bar{A}) = 0.556$$



在此基础上，我们再用一次贝叶斯公式计算：

$$P(A|B)$$

亦即小孩第二次说谎后，他的可信程度变为：

$$\begin{aligned} P(A|B) &= \frac{P(A)P(B|A)}{P(A)P(B|A) + P(\bar{A})P(B|\bar{A})} \\ &= \frac{0.444 \times 0.1}{0.444 \times 0.1 + 0.556 \times 0.5} = 0.138 \end{aligned}$$

说明村民们经过两次上当，对这个小孩的可信程度已从0.8下降到0.138，如此低的可信程度，村民听到第三次呼叫怎么再会上山打狼呢？





2.2 基于Bayes估计的身份识别方法

贝叶斯估计法是静态环境中信息融合的一种方法，适用于具有可加高斯噪声的不确定信息处理。

贝叶斯估计将各种各样的不确定信息表示为概率，通过贝叶斯条件概率公式进行处理，最后通过先验信息和样本信息合成的后验部分信息对目标进行推断。该算法需要得知目标的先验概率。

Bayes方法用于多传感器信息融合时，要求系统可能的决策相互独立，这样这些决策可以看做一个样本空间的划分。

设系统可能的决策为 A_1, A_2, \dots, A_n ，当某一传感器对系统进行观测时，得到观测结果 B ，如果能够利用先验概率 $P(A_i)$ 和条件概率 $P(B|A_i)$ ，则可以根据贝叶斯公式将先验概率更新为后验概率 $P(A_i|B)$ 。

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$

多个传感器
怎么办？

当系统有两个传感器对其观测时，一个传感器观测为 B ，另一个传感器观测结果为 C ，关于各决策 A_i 的条件概率为 $P(B/A_i), P(C/A_i), (i=1, 2, \dots, n)$ ，当假设 A_i, B, C 之间是相互独立时，则 B, C 观测总的后验概率公式可表示为：

$$P(A_i | BC) = \frac{P(BC | A_i) P(A_i)}{\sum_{i=1}^n P(BC | A_i) P(A_i)}$$
$$= \frac{P(B | A_i) P(C | A_i) P(A_i)}{\sum_{i=1}^n P(B | A_i) P(C | A_i) P(A_i)}$$

所有能判断目标为 A_i 的所有可能事件的概率之和

所有能判断目标为 $\{A_1, A_2, \dots, A_n\}$ 中所有可能事件的概率之和

拓展到一般情况

假设有 m 个传感器用于获取未知目标的属性。每一个传感器基于传感器观测和特定的传感器分类算法提供一个关于目标属性的说明。

设 O_1, O_2, \dots, O_n 为所有可能的 n 个目标， D_1, D_2, \dots, D_m 表示 m 个传感器各自对于目标属性的说明（观测结果）。



O_1, O_2, \dots, O_n 实际上构成了观测空间的 n 个互不相容的穷举假设，则根据前面几个式子得到：

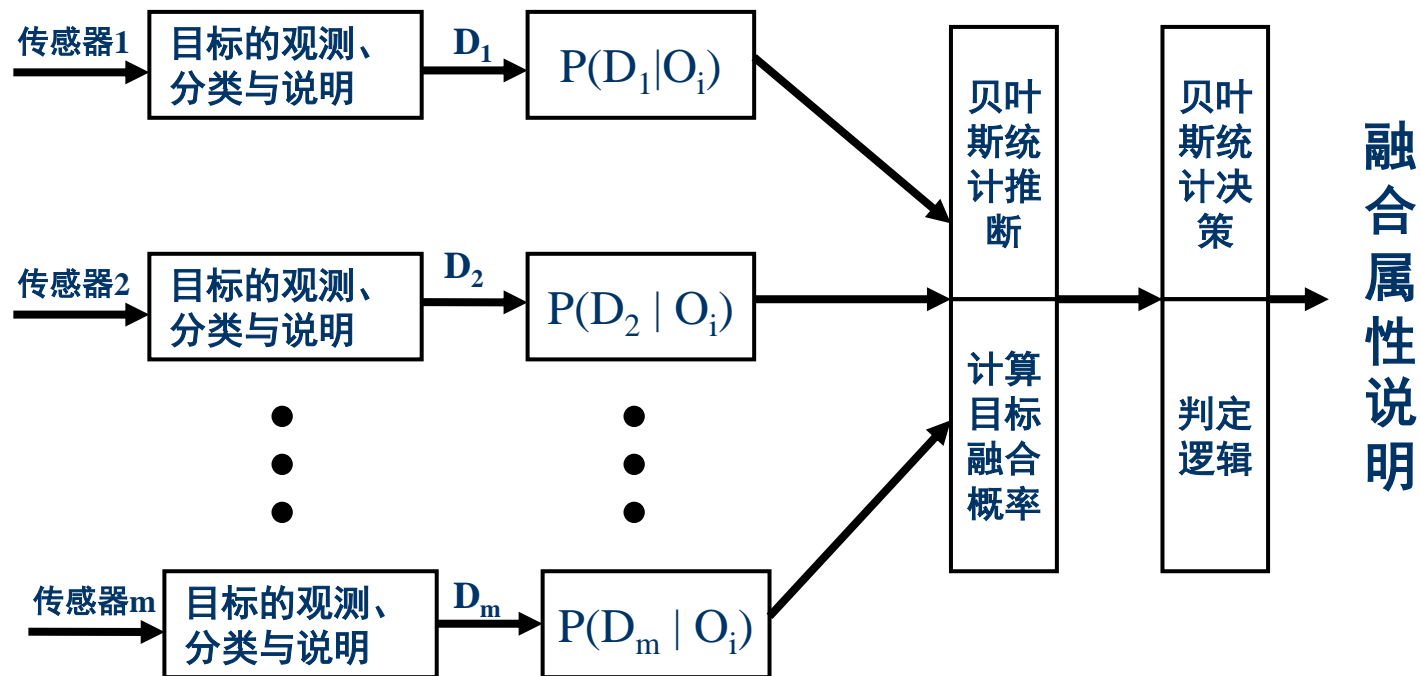
$$\sum_{i=1}^n P(O_i) = 1$$

给定目标属性 D_j 情况下，假设 O_i 为真的后验概率为：

$$P(O_i | D_j) = \frac{P(D_j | O_i) P(O_i)}{\sum_{i=1}^n P(D_j | O_i) P(O_i)} \quad i = 1, 2, \dots, n; j = 1, 2, \dots, m$$

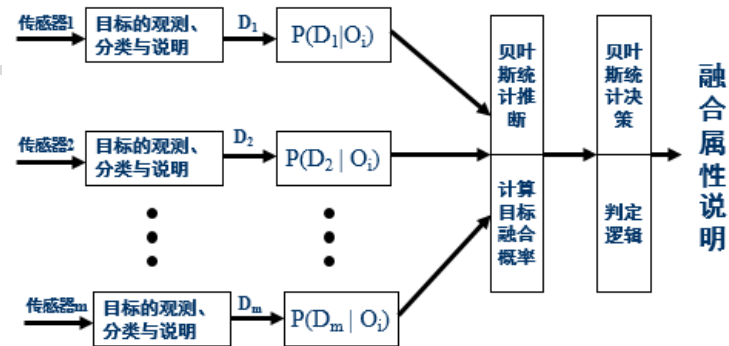
所有能判断目标为 O_i 的所有可能事件的概率之和

所有能判断目标为 $\{O_1, O_2, \dots, O_n\}$ 中所有可能事件的概率之和



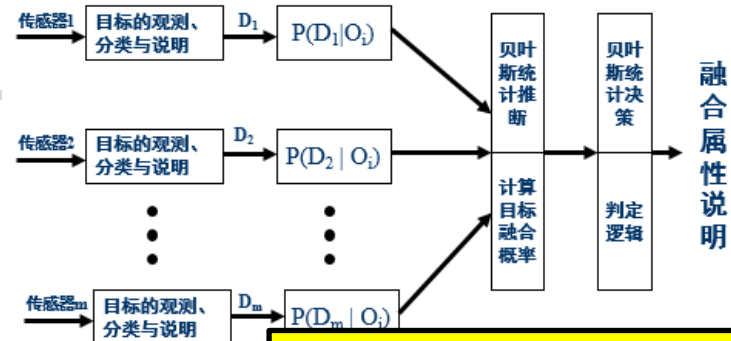
$$P(O_i | D_1, D_2, \dots, D_m), \quad i=1, 2, \dots, m$$

基于贝叶斯统计理论的属性识别（身份识别）



Bayes融合识别算法的主要步骤为：

- (1) 将每个传感器关于目标的观测转化为目标属性的分类与说明 D_1, D_2, \dots, D_m 。
- (2) 计算每个传感器关于目标属性说明或判定的确定性，即 $P(D_j/O_i)$, $j=1, 2, \dots, m$; $i=1, 2, \dots, n$ 。



(3) 计算目标属性的融合概率：

$$P(O_i | D_1, D_2, \dots, D_m) = \frac{P(D_1, D_2, \dots, D_m | O_i) P(O_i)}{\sum_{i=1}^n P(D_1, D_2, \dots, D_m | O_i) P(O_i)} \quad i=1, 2, \dots, n$$

所有能判断目标为 O_i 的所有可能事件的概率之和

所有能判断目标为 $\{O_1, O_2, \dots, O_n\}$ 中所有可能事件的概率之和

如果 D_1, D_2, \dots, D_m 相互独立，则

$$P(D_1, D_2, \dots, D_m | O_i) = P(D_1 | O_i) P(D_2 | O_i) \cdots P(D_m | O_i)$$

系统的决策是取具有最大后验概率的决策。



采用中频雷达、ESM（电子支援测量系统）和IFF传感器（敌我识别）三种传感器对目标进行检测，假设已获得两个测量周期的先验概率分配为：

①中频雷达：

$P(\text{民航})=0.3$ ， $P(\text{轰炸机})=0.4$ ， $P(\text{不明})=0.3$

$P(\text{民航})=0.3$ ， $P(\text{轰炸机})=0.5$ ， $P(\text{不明})=0.2$

②ESM：

$P(\text{敌轰1})=0.4$ ， $P(\text{敌轰2})=0.3$ ， $P(\text{我轰})=0.2$ ， $P(\text{不明})=0.1$

$P(\text{敌轰1})=0.4$ ， $P(\text{敌轰2})=0.4$ ， $P(\text{我轰})=0.1$ ， $P(\text{不明})=0.1$

③IFF：

$P(\text{我机})=0.6$ ， $P(\text{不明})=0.4$ ；

$P(\text{我机})=0.4$ ， $P(\text{不明})=0.6$

采用基于Bayes多传感器的数据融合方法实现目标识别。



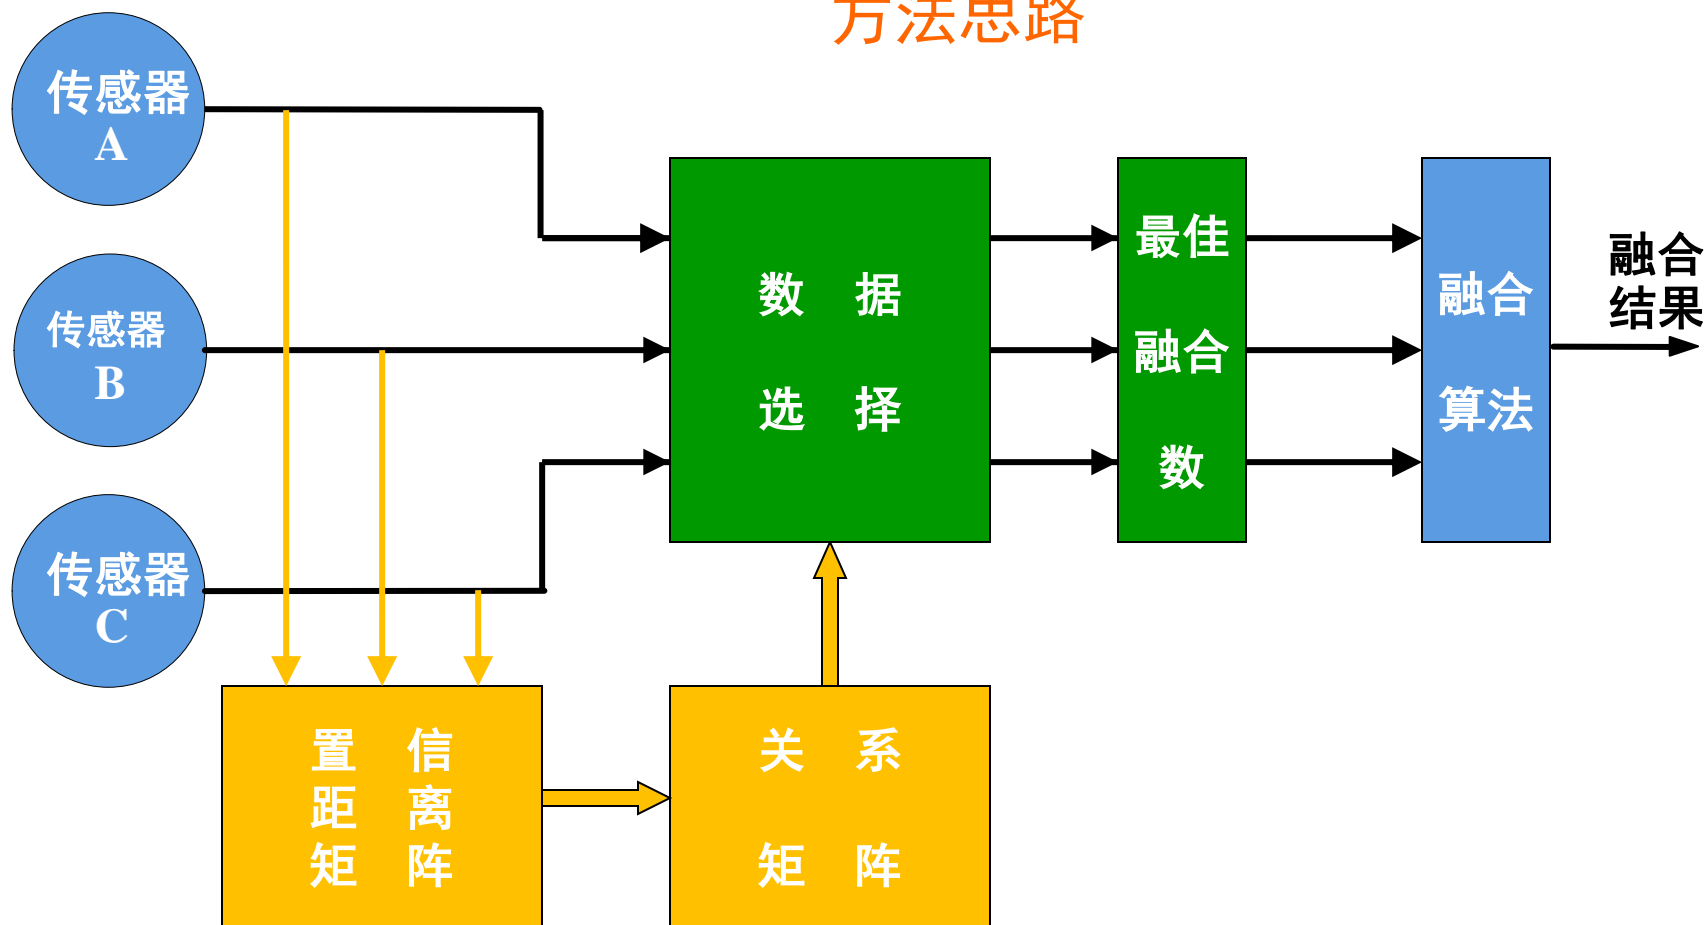
参考文献

- ❖ 王俊林，张剑云. 采用Bayes多传感器数据融合方法进行目标识别 [J]，传感器技术，2015,24（10）：86-88



2.3 基于Bayes估计的传感器检测数据融合

方法思路





基本理论和方法—置信距离和置信距离矩阵

❖ 利用多个传感器测量某参数的过程中有两个随机变量，一是被测参数 μ ，二是每个传感器的输出 X_i , $i=1, 2, \dots, m$ 。一般认为它们服从正态分布，用 x_i 表示第 i 个测量值的一次测量输出，它是随机变量 X_i 的一次取样。

❖ 设：

$$\mu \sim N(\mu_0, \sigma_0^2)$$

$$X_i \sim N(\mu_i, \sigma_i^2)$$


单变量正态分布

单变量正态分布概率密度函数定义为：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]$$

$$\mu = E\{x\} = \int_{-\infty}^{\infty} xp(x)dx$$

$$\sigma^2 = E\{(x-\mu)^2\} = \int_{-\infty}^{\infty} (x-\mu)^2 p(x)dx$$



单变量正态分布概率密度函数 $p(x)$ 完全可由 μ 与 σ^2 两个参数确定，记作 $N(\mu, \sigma^2)$



基本理论和方法—置信距离和置信距离矩阵

- ❖ 为对传感器输出数据进行选择，必须评估其可靠性，为此定义各数据间的置信距离。
- ❖ 用 X_i 、 X_j 表示第 i 个和第 j 个传感器的输出，则其一次读数 x_i 和 x_j 之间的置信距离定义为：

$$d_{ij} = 2 \int_{x_i}^{x_j} p_i(x|x_i) dx$$

$$d_{ji} = 2 \int_{x_j}^{x_i} p_j(x|x_j) dx$$

基本理论和方法—置信距离和置信距离矩阵

❖ 若 X_i 、 X_j 服从正态分布，则上式中：

$$p_i(x|x_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left\{-\frac{1}{2}\left(\frac{x-x_i}{\sigma_i}\right)^2\right\}$$

$$p_j(x|x_j) = \frac{1}{\sqrt{2\pi}\sigma_j} \exp\left\{-\frac{1}{2}\left(\frac{x-x_j}{\sigma_j}\right)^2\right\}$$

故可知：

❖ 当 $x_i = x_j$ 时， $d_{ij} = d_{ji} = 0$

❖ 当 $x_i \gg x_j$ 或 $x_j \gg x_i$ 时， $d_{ij} = d_{ji} = 1$

基本理论和方法—置信距离和置信距离矩阵

- ❖ **置信距离矩阵**：对 m 个传感器的一次测量数据，利用上述方法可以分别计算任意两个传感器数据之间的置信距离 d_{ij} , $i, j = 1, 2, \dots, m$ 得到一个 $m*m$ 矩阵。

$$D_m = \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1m} \\ d_{21} & d_{22} & \cdots & d_{2m} \\ \cdots & \cdots & \cdots & \cdots \\ d_{m1} & d_{m2} & \cdots & d_{mm} \end{bmatrix}$$

基本理论和方法—关系矩阵和数据选择

- ❖ 根据具体问题选择合适的临界值 β_{ij} 由 d_{ij} 对数据的可靠性进行判定。

$$r_{ij} = \begin{cases} 1 & d_{ij} \leq \beta_{ij} \\ 0 & d_{ij} > \beta_{ij} \end{cases}$$

- ❖ 由此得到一个二值矩阵，称为关系矩阵。

$$R_m = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ r_{21} & r_{22} & \cdots & r_{2m} \\ \cdots & \cdots & \cdots & \cdots \\ r_{m1} & r_{m2} & \cdots & r_{mm} \end{bmatrix}$$

基本理论和方法—基于Bayes估计的数据融合算法

- ❖ 设被测参数 $\mu \sim N(\mu_0, \sigma_0^2)$ ，第 k 个传感器的测量数据 $X_k \sim N(\mu_k, \sigma_k^2)$ ，经过删选，选择 L 个数据作为最佳融合数。融合结果 $\hat{\mu}$ 为：

$$\hat{\mu} = \frac{\sum_{k=1}^L \frac{x_k}{\sigma_k^2} + \frac{\mu_0}{\sigma_0^2}}{\sum_{k=1}^L \frac{1}{\sigma_k^2} + \frac{1}{\sigma_0^2}}$$



基于Bayes估计的数据融合一般步骤

- ① 计算 m 个传感器数据的置信距离矩阵，为简化计算，当测试数据服从正态分布时可利用高斯误差函数计算置信距离。

$$d_{ij} = erf\left(\frac{x_j - x_i}{\sqrt{2}\sigma_i}\right)$$

$$erf(\theta) = \frac{2}{\sqrt{\pi}} \int_0^\theta e^{-u^2} du$$

基于Bayes估计的数据融合一般步骤

- ② 选择合适的距离临界值，由置信距离矩阵产生关系矩阵。

$$r_{ij} = \begin{cases} 1 & d_{ij} \leq \beta_{ij} \\ 0 & d_{ij} > \beta_{ij} \end{cases}$$

- ③ 由关系矩阵对多传感器数据进行选择，产生最佳融合数。

基于Bayes估计的数据融合一般步骤

- ④ 将 μ_0 、 σ_0^2 和最佳融合数对应的 x_k 、 σ_k^2 代入 Bayes 融合估计公式求的参数估计值。

$$\hat{\mu} = \frac{\sum_{k=1}^L \frac{x_k}{\sigma_k^2} + \frac{\mu_0}{\sigma_0^2}}{\sum_{k=1}^L \frac{1}{\sigma_k^2} + \frac{1}{\sigma_0^2}}$$



参考文献

- ❖ 吴小俊等，基于Bayes估计的多传感器数据融合方法研究[J],系统工程理论与实践，2000.

如何确定先验信息

1) 客观法：利用历史观测，对随机变量 θ 的观测资料，或者虽然无法直接观测 θ ，却能观测某一与之有关的随机变量 x ， x 间接地提供了 θ 的信息。

2) 主观法：利用主观概率假定先验分布，依据统计者的经验对各种事件鉴定的概率，构造先验分布。尽管统计学者在提出某种先验分布的形式时，常有其以往的经验作为背景，但这种经验不是系统、有条理的。




故据此对各种事件假定概率时，不可避免地有其主观成分，常称为主观概率。基于这种方法的*Bayes*统计也称主观*Bayes*统计。在这种情形下，主观先验分布的形式因人而异，这正是*Bayes*统计的支持者和反对者之间引起重大争论的一个问题。



本节小结：

1. 多传感器信息融合体系结构
2. 信息融合中的时空配准（时间配准、空间配准）
3. 基于Bayes估计的信息融合方法及应用



Thanks

