



北京航空航天大学
BEIHANG UNIVERSITY

矩阵理论

王磊

自动化科学与电气工程学院

第四章 矩阵分析

函 数 矩 阵

第四章 矩阵分析——函数矩阵

定义4.8.1(函数矩阵) 以变量 t 的函数为元素的矩阵

$A(t) = (a_{ij}(t))_{m \times n}$ 称为**函数(值)矩阵**;

若矩阵 $A(t)$ 的每个元素 $a_{ij}(t)$ 在 $[a, b]$ 上是连续、可微或可积时, 则称 $A(t)$ 在 $[a, b]$ 上**连续、可微或可积**, 并定义

$$A'(t) = \frac{d}{dt} A(t) = (a'_{ij}(t))_{m \times n}$$

$$\int_a^b A(t) dt = \left(\int_a^b a_{ij}(t) dt \right)_{m \times n}$$

第四章 矩阵分析——函数矩阵

例4.8.1 求函数矩阵 $A(t) = \begin{bmatrix} \sin t & \cos t & t \\ e^t & e^{2t} & e^{3t} \\ 0 & 1 & t^2 \end{bmatrix}$ 的导数.

第四章 矩阵分析——函数矩阵

命题4.8.1 设 $A(t)$ 和 $B(t)$ 是适当阶的可微矩阵, 则

$$(1) \quad \frac{d}{dt}(A(t) + B(t)) = \frac{d}{dt}A(t) + \frac{d}{dt}B(t);$$

(2) $\lambda(t)$ 为可微标量函数时,

$$\frac{d}{dt}(\lambda(t)A(t)) = \frac{d\lambda(t)}{dt}A(t) + \lambda(t)\frac{d}{dt}A(t);$$

$$(3) \quad \frac{d}{dt}(A(t)B(t)) = \frac{dA(t)}{dt}B(t) + \frac{dB(t)}{dt}A(t);$$

$$(4) \quad u = f(t) \text{可微时, } \frac{d}{dt}(A(u)) = f'(t)\frac{d}{dt}A(t);$$

第四章 矩阵分析——函数矩阵

命题4.8.1 (续)

(5) 当 $A(t)$ 是可逆矩阵时, 有

$$\frac{d}{dt} \left(A^{-1}(t) \right) = -A^{-1}(t) \left(\frac{d}{dt} A(t) \right) A^{-1}(t).$$



第四章 矩阵分析——函数矩阵

命题4.8.2 设 $A \in \mathbb{C}^{n \times n}$, 则有

$$(1) \quad \frac{d}{dt} e^{At} = A e^{At} = e^{At} A;$$

$$(2) \quad \frac{d}{dt} \sin(At) = A \cos(At) = (\cos At)A;$$

$$(3) \quad \frac{d}{dt} \cos(At) = -A \sin(At) = -(\sin At)A.$$

第四章 矩阵分析——函数矩阵

推论4.8.1 设 $A \in \mathbb{C}^{n \times n}$, 则有

$$(1) \int_{t_0}^t A e^{As} ds = e^{At} - e^{At_0};$$

$$(2) \int_{t_0}^t A \sin(As) ds = \cos(At_0) - \cos(At);$$

$$(3) \int_{t_0}^t A \cos(As) ds = \sin(At) - \sin(At_0).$$

第四章 矩阵分析——函数矩阵

命题4.8.3 设 $A(t)$ 和 $B(t)$ 是 $[a, b]$ 上适当阶的可积矩阵, $\lambda \in \mathbb{C}$, 则有

$$(1) \quad \int_a^b (A(t) + B(t)) dt = \int_a^b A(t) dt + \int_a^b B(t) dt$$

$$(2) \quad \int_a^b \lambda A(t) dt = \lambda \int_a^b A(t) dt;$$

$$(3) \quad A(t) \text{在} [a, b] \text{上连续时, 则} \forall t \in (a, b)$$

$$\frac{d}{dt} \left(\int_a^t A(\tau) d\tau \right) = A(t);$$

$$(4) \quad A(t) \text{在} [a, b] \text{上连续时, 有}$$

$$\int_a^b A'(\tau) d\tau = A(b) - A(a).$$

第四章 矩阵分析——函数矩阵

定义4.8.2(矩阵对矩阵的导数) 设 $F(X) =$

$(f_{ij}(X)) \in \mathbb{C}^{m \times n}$ 是 $X \in \mathbb{C}^{p \times q}$ 的函数矩阵, $f_{ij}(X)$, $i = 1, \dots, m, j = 1, \dots, n$ 作为 $X \in \mathbb{C}^{p \times q}$ 的多元函数是可微的, 令

$$\frac{dF(X)}{dX} = \left(\frac{\partial F}{\partial x_{ij}} \right)_{mp \times nq} = \begin{bmatrix} \frac{\partial F}{\partial x_{11}} & \frac{\partial F}{\partial x_{12}} & \cdots & \frac{\partial F}{\partial x_{1q}} \\ \frac{\partial F}{\partial x_{21}} & \frac{\partial F}{\partial x_{22}} & \cdots & \frac{\partial F}{\partial x_{2q}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial F}{\partial x_{p1}} & \frac{\partial F}{\partial x_{p2}} & \cdots & \frac{\partial F}{\partial x_{pq}} \end{bmatrix}$$

式中, $\frac{\partial F}{\partial x_{ij}} = \left(\frac{\partial f_{kl}(x)}{\partial x_{ij}} \right)$, $k = 1, \dots, m, l = 1, \dots, n$,

称 $\frac{dF(X)}{dX}$ 为 $F(X)$ 对 X 的导数.

第四章 矩阵分析——函数矩阵

注1: 定义4.8.2既是对定义4.8.1中矩阵函数导数的扩展, 也隐含着向量对向量、向量对矩阵、矩阵对向量和矩阵对矩阵的导数定义.



第四章 矩阵分析——函数矩阵

例4.8.2 设 $f(\mathbf{x}) = f(x_1, \dots, x_n)$ 是 n 元实可微函数, 则

$$\frac{df}{d\mathbf{x}} = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right]$$

式中, $\mathbf{x} = [x_1, \dots, x_n]$.

我们常称 $\frac{df}{d\mathbf{x}}$ 为 f 的**梯度向量**, 常记为 $\nabla(f)$.

第四章 矩阵分析——函数矩阵

例4.8.3 设 $f(\mathbf{x}) = [f_1, f_2, \dots, f_m]^T \in F^m$ 是 n 元实可微向量函数, 即每个 n 元函数 $f_i(\mathbf{x}) = f_i(x_1, \dots, x_n)$, $1 \leq i \leq m$ 均为可微函数, 其中 $\mathbf{x} = [x_1, \dots, x_n]$ 为行向量.

$$\frac{df}{d\mathbf{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \dots & \dots & \dots & \dots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \dots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

矩阵 $\frac{df}{d\mathbf{x}}$ 常称为向量函数 f 的 **Jacobian** 矩阵.

第四章 矩阵分析——函数矩阵

例4.8.4 设常矩阵 $A \in \mathbb{R}^{n \times n}$ 和未定元向量 $\mathbf{x} \in \mathbb{R}^n$,

求 $\frac{dA\mathbf{x}}{d\mathbf{x}^T}$.

$$\frac{d\mathbf{y}}{d\mathbf{x}^T} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \vdots & \vdots \\ \frac{\partial y_n}{\partial x_1} & \cdots & \frac{\partial y_n}{\partial x_n} \end{bmatrix} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \vdots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = A$$



第四章 矩阵分析——函数矩阵

例4.8.5 设常矩阵 $A \in \mathbb{R}^{n \times n}$, $\mathbf{x}, \mathbf{b} \in \mathbb{R}^n$, 求 $\frac{d}{dx}(\mathbf{b}^T \mathbf{x})$ 和 $\frac{d}{dx}(\mathbf{x}^T A \mathbf{x})$.

$$\frac{d}{dx}(\mathbf{b}^T \mathbf{x}) = \begin{bmatrix} \frac{\partial(\mathbf{b}^T \mathbf{x})}{\partial x_1} \\ \frac{\partial(\mathbf{b}^T \mathbf{x})}{\partial x_2} \\ \vdots \\ \frac{\partial(\mathbf{b}^T \mathbf{x})}{\partial x_n} \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} = \mathbf{b}$$

$$\frac{d}{dx}(\mathbf{x}^T A \mathbf{x}) = \begin{bmatrix} \sum_{i=1}^n a_{i1}x_i + \sum_{j=1}^n a_{1j}x_j \\ \sum_{i=1}^n a_{i2}x_i + \sum_{j=1}^n a_{2j}x_j \\ \vdots \\ \sum_{i=1}^n a_{in}x_i + \sum_{j=1}^n a_{nj}x_j \end{bmatrix} = (A^T + A)\mathbf{x}$$



第四章 矩阵分析——函数矩阵

设 $\mathbf{u}(\mathbf{x}), \mathbf{v}(\mathbf{x}), \mathbf{x} \in \mathbb{R}^n$, 则有

$$\frac{d\mathbf{u}^T \mathbf{v}}{d\mathbf{x}} = \frac{d\mathbf{u}^T}{d\mathbf{x}} \mathbf{v} + \frac{d\mathbf{v}^T}{d\mathbf{x}} \mathbf{u}$$

$$\frac{d\mathbf{u} \mathbf{v}^T}{d\mathbf{x}} = \frac{d\mathbf{u}}{d\mathbf{x}} \mathbf{v}^T + (\mathbf{u} \otimes I_n) \frac{d\mathbf{v}^T}{d\mathbf{x}}$$

网上各种公式一定要验证！

第四章 矩阵分析——函数矩阵

【应用】：求解最小二乘问题

$$\min_{\boldsymbol{x} \in \mathbb{R}^n} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2$$

式中, $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ 和 $\boldsymbol{b} \in \mathbb{R}^n$ 给定, $\boldsymbol{x} \in \mathbb{R}^n$ 待定向量.



第四章 矩阵分析——函数矩阵

引理4.8.1(无约束极值的必要条件) 设 $X \in \mathbb{R}^{m \times n}$, $f(X)$ 是关于矩阵变量 X 的连续可导函数. 若 X_0 是 $f(X)$ 的一个极值点, 则

$$\left. \frac{df(X)}{dX} \right|_{X=X_0} = 0$$

若 $f(X)$ 还是关于矩阵变量 X 的凸函数, 则 $f(X)$ 的极值点必是最值点.

第四章 矩阵分析——函数矩阵

补充: 考查 n 元函数 $f(\mathbf{x})$ 在 $\mathbf{x}_0 = [x_{10}, x_{20}, \dots, x_{n0}]^T$ 的泰勒展开.

$$\begin{aligned} f(\mathbf{x}) = & f(\mathbf{x}_0) + \frac{\partial f(\mathbf{x}_0)}{\partial x_1} (x_1 - x_{10}) + \dots + \frac{\partial f(\mathbf{x}_0)}{\partial x_n} (x_n - x_{n0}) \\ & + \frac{1}{2!} \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_1^2} (x_1 - x_{10})^2 \\ & + \frac{1}{2!} \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_1 \partial x_2} (x_1 - x_{10})(x_2 - x_{20}) \\ & + \dots + \frac{1}{2!} \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_n^2} (x_n - x_{n0})^2 + \dots \end{aligned}$$



第四章 矩阵分析——函数矩阵

补充: 考查 n 元函数 $f(\mathbf{x})$ 在 $\mathbf{x}_0 = [x_{10}, x_{20}, \dots, x_{n0}]^T$ 的泰勒展开.

$$\begin{aligned} f(\mathbf{x}) = & f(\mathbf{x}_0) + \left(\frac{df(\mathbf{x}_0)}{d\mathbf{x}} \right)^T (\mathbf{x} - \mathbf{x}_0) \\ & + \frac{1}{2!} (\mathbf{x} - \mathbf{x}_0)^T H(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0) + \dots \end{aligned}$$



第四章 矩阵分析——函数矩阵

补充: 考查 n 元函数 $f(\mathbf{x})$ 在 $\mathbf{x}_0 = [x_{10}, x_{20}, \dots, x_{n0}]^T$ 的泰勒展开.

$$H(\mathbf{x}_0) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_2^2} & \dots & \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x}_0)}{\partial x_n^2} \end{bmatrix}$$
$$= \frac{d}{d\mathbf{x}^T} \left(\frac{df(\mathbf{x}_0)}{d\mathbf{x}} \right)$$

上述矩阵称为**Hessian矩阵**.



第四章 矩阵分析——函数矩阵

【应用】：考查一阶线性常系数微分方程组的求解问题.

$$\begin{cases} \frac{dx_1(t)}{dt} = a_{11}x_1(t) + \cdots + a_{1n}x_n(t) + f_1(t) \\ \vdots \\ \frac{dx_n(t)}{dt} = a_{n1}x_1(t) + \cdots + a_{nn}x_n(t) + f_n(t) \end{cases}$$



第四章 矩阵分析——函数矩阵

例4.8.6 求下列方程组的解

$$\begin{cases} \frac{d\mathbf{x}(t)}{dt} = A\mathbf{x}(t) + \mathbf{f}(t) \\ \mathbf{x}(t_0) = \mathbf{x}_0 \end{cases}$$

其中参数分别为

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & -1 & 3 \end{bmatrix},$$

$$\mathbf{f}(t) = [1, -t, t]^T, \mathbf{x}_0 = [1, 0, -1]^T.$$

第四章 矩阵分析——函数矩阵

再考查 n 阶常系数微分方程的求解问题:

$$y^{(n)} + a_{n-1}y^{(n-1)} + \cdots + a_0y = u(t)$$

式中, a_0, \cdots, a_{n-1} 为常数, $u(t)$ 为已知函数.

当 $u(t) \neq 0$ 时, 称上述方程为**非齐次微分方程**, 否则称为**齐次微分方程**.

第四章 矩阵分析——函数矩阵

定义

$$\begin{aligned}x_1 &= y \\x_2 &= \dot{y} \\&\vdots \\x_n &= y^{(n-1)}\end{aligned}$$

由此, 得到如下方程

$$\dot{x} = Ax + f(x)$$

上式在现代控制理论中称为**状态方程**, $x(t)$ 称为**状态向量**, A 为**系统矩阵**. 此时, 将 n 阶常系数微分方程转化为状态方程进行求解.

第四章 矩阵分析——函数矩阵

例4.8.7 求解非齐次线性微分方程组

$$y^{(3)} - 6\ddot{y} + 11\dot{y} - 6y = \sin t$$

式中, $\ddot{y}(0) = \dot{y}(0) = y(0) = 0$.

第四章 矩阵分析——函数矩阵

【应用】: 系统的**可控性**是指对任意给定的系统初始状态, 均存在一个合适控制输入使得系统状态在有限时间转移至状态零点. 它表征了系统输入对系统状态的有效控制能力, 是现代控制理论的基本概念.

例4.8.8即为线性定常系统可控的充分必要条件.

第四章 矩阵分析——函数矩阵

例4.8.8 n 阶Hermite矩阵 $W(0, t_1)$ 是正定的当且仅当矩阵 $\text{rank}(C) = n$, 其中

$$W(0, t_1) = \int_0^{t_1} e^{-At} B B^T e^{-A^T t} dt$$
$$C = [B, AB, \dots, A^{n-1}B]$$

$A \in \mathbb{R}^{n \times n}$ 是线性定常系统的系统矩阵, $B \in \mathbb{R}^{n \times p}$ 是线性定常系统的输入矩阵, t_1 是给定的正常数.

第四章 矩阵分析

应用：主元分析法(自学)



第四章 矩阵分析——应用：主元分析法

主元分析法是一种常用的数据降维方法,其目的是在“信息损失”较小的前提下,将高维数据转换到低维. 基于此,我们给出这一问题的数学描述.

假设一组数据有 n 个样本,即 $\mathbf{x}_1, \cdots \mathbf{x}_n$, 其中, $\mathbf{x}_i \in \mathbb{R}^p$ 表示每个样本向量(或随机向量).

设降维后的样本向量为 $\mathbf{y}_i \in \mathbb{R}^q$ ($q < p$, 否则失去降维意义), 则 $\text{span}(\mathbf{y}_1, \cdots \mathbf{y}_n)$ 应与 $\text{span}(\mathbf{x}_1, \cdots \mathbf{x}_n)$ 同构.



第四章 矩阵分析——应用：主元分析法

由此, 存在同构映射 f 使得原像 \mathbf{x}_i 与 \mathbf{y}_i 满足

$$\mathbf{y}_i = f(\mathbf{x}_i)$$

由于 f 是线性映射, 故可等价表示为

$$\mathbf{y}_i = W\mathbf{x}_i = \begin{bmatrix} \mathbf{w}_1^T \mathbf{x}_i \\ \vdots \\ \mathbf{w}_p^T \mathbf{x}_i \end{bmatrix}$$

式中, 矩阵 $W \in \mathbb{R}^{q \times p}$, $\mathbf{w}_i \in \mathbb{R}^p$ 为待定向量.

第四章 矩阵分析——应用：主元分析法

考查表达式 $\mathbf{w}_k^T \mathbf{x}_i$. 在欧氏空间中,

$$\mathbf{w}_k^T \mathbf{x}_i = (\mathbf{w}_k, \mathbf{x}_i)$$

若 $\|\mathbf{w}_k\| = 1$, 则上式表示向量 \mathbf{x}_i 在向量 \mathbf{w}_k 的正交投影的长度, 即映射的 \mathbf{y}_i 的每一个分量是原像 \mathbf{x}_i 在矩阵 W 行向量的正交投影.


为保证 \mathbf{y}_i 尽量继承原始变量特征, 应选择 $\mathbf{w}_i (i = 1, \dots, q)$ 是正交向量组.

所以矩阵 W 是行正交规范矩阵, 即向量组 $\mathbf{w}_i (i = 1, \dots, q)$ 是单位正交向量组.

第四章 矩阵分析——应用：主元分析法

为刻画“信息损失”较小,我们考查二维平面的一个例子.

确定待定向量 (组) w



第四章 矩阵分析——应用：主元分析法

在数学上,我们可以用的方差来表述样本分散的程度. 于是,优化目标可表达为

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w}} \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^T \mathbf{x}_i - \mu)^2$$

式中, μ 是样本投用的均值, 其定义式为

$$\mu = \frac{1}{n} \sum_{i=1}^n \mathbf{w}^T \mathbf{x}_i$$



第四章 矩阵分析——应用：主元分析法

注意到

$$\begin{aligned}\sigma^2 &= \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^T \mathbf{x}_i - \mu)^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}))^2 \\ &= \frac{1}{n} \sum_{i=1}^n \mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w} \\ &= \mathbf{w}^T \left(\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \right) \mathbf{w}\end{aligned}$$

并定义矩阵

$$\mathbf{x} = [\mathbf{x}_1 - \bar{\mathbf{x}}, \mathbf{x}_2 - \bar{\mathbf{x}}, \dots, \mathbf{x}_n - \bar{\mathbf{x}}] \in \mathbb{R}^{p \times n}$$

第四章 矩阵分析——应用：主元分析法

则方差 σ^2 可进一步改下为

$$\sigma^2 = \mathbf{w}^T \left(\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T \right) \mathbf{w} = \mathbf{w}^T \mathbf{C} \mathbf{w}$$

式中, $\mathbf{C} = \frac{1}{n} \mathbf{x} \mathbf{x}^T \in \mathbb{R}^{p \times p}$ 是随机变量 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 的协方差矩阵.

由引理3.9.2知, \mathbf{C} 半正定实对称矩阵. 故

$$\sigma^2 = R(\mathbf{w})$$

式中, $R(\mathbf{w})$ 是协方差矩阵 \mathbf{C} 的Rayleigh商.

第四章 矩阵分析——应用：主元分析法

方法一：为讨论方便, 设 $\lambda_1 > \lambda_2 > \cdots \lambda_m$ 是矩阵 C 的 m 个互异特征值, 其代数重数分别为 d_1, \cdots, d_l 且有 $d_1 + \cdots + d_l = p$. 根据定理4.3.4知,

$$R(\mathbf{w}) \leq \lambda_1$$

上式等号成立的条件为向量 \mathbf{w} 取为属于特征值 λ_1 的 d_1 个单位正交特征向量组中的一个向量. 由此, 我们找到了 d_1 个 \mathbf{w} 向量. 那么余下的 $q - d_1$ 个 \mathbf{w} 向量应如何确定呢?

第四章 矩阵分析——应用：主元分析法

我们应在特征值为 $\lambda_2, \dots, \lambda_m$ 的特征子空间的和空间来寻找（为什么？），即

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w} \in \left(\bigoplus_{i=2, \dots, m} E(\lambda_i) \right)} R(\mathbf{w})$$

根据定理4.3.4知，

$$\max_{\mathbf{w} \in \left(\bigoplus_{i=2, \dots, m} E(\lambda_i) \right)} R(\mathbf{w}) \leq \lambda_2$$



第四章 矩阵分析——应用：主元分析法

上式等号成立的条件为向量 \mathbf{w} 取为属于特征值 λ_2 的 d_2 个单位正交特征向量组中的一个向量. 由此, 我们找到了 d_2 个 \mathbf{w} 向量. 依次类推, 我们可以找到 q 个满足要求的向量 \mathbf{w} . 这 q 个向量 \mathbf{w} 恰好是协方差矩阵 C 的属于前 q 最大个特征值（计重数）的单位正交特征向量即可得到.

第四章 矩阵分析——应用：主元分析法

方法二：由Lagrange乘子法构造目标函数：

$$L(\mathbf{w}, \lambda) = \mathbf{w}^T C \mathbf{w} + \lambda(1 - \mathbf{w}^T \mathbf{w})$$

对 $L(\mathbf{w}, \mu)$ 求偏导数, 得

$$\frac{\partial L(\mathbf{w}, \mu)}{\partial \mathbf{w}} = 2C\mathbf{w} - 2\lambda\mathbf{w}$$

令上式为零, 得以下极值条件

$$C\mathbf{w} = \lambda\mathbf{w}$$

上式表明, λ 是协方差矩阵 C 的特征值, \mathbf{w} 是属于特征值 λ 的单位特征向量.

第四章 矩阵分析——应用：主元分析法

将 $C\mathbf{w} = \lambda\mathbf{w}$ 目标函数, 得

$$\sigma^2 = \lambda$$

为保证方差最大, 只要我们对矩阵 C 的特征值进行排序, 然后选取前属于前 q 最大个特征值(计重数)的单位正交特征向量即可得到 W , 上式表明**投影后的方程就是协方差矩阵的特征值.**

